

UNIVERZA NA PRIMORSKEM  
FAKULTETA ZA MATEMATIKO, NARAVOSLOVJE IN  
INFORMACIJSKE TEHNOLOGIJE

Zaključna naloga

**Razpoznavanje gibanja na osnovi encefalografije**

(Movement recognition based on encephalography)

Ime in priimek: Marko Rozman

Študijski program: Računalništvo in informatika

Mentor: Docent dr. Peter Rogelj

**Koper, Julij 2024**

# Ključna dokumentacijska informacija

Ime in PRIIMEK:

Naslov zaključne naloge:

Kraj:

Leto:

Število listov:

Število slik:

Število tabel:

Število prilog:

Število strani prilog:

Število referenc:

Mentor:

Somentor:

Ključne besede:

Math. Subj. Class. (2010):

**Izvleček:**  
Izvleček predstavlja kratek, a jedrnat prikaz vsebine naloge. V največ 250 besedah nakažemo problem, metode, rezultate, ključne ugotovitve in njihov pomen.

## Key words documentation

Name and SURNAME:

Title of final project paper:

Place:

Year:

Number of pages:

Number of figures:

Number of tables:

Number of appendices:

Number of appendix pages:

Number of references:

Mentor: title First Name Last Name, PhD

Co-Mentor:

Keywords:

Math. Subj. Class. (2010):

**Abstract:**

## Zahvala

Tu se zahvalimo sodelujočim pri zaključni nalogi, osebam ali ustanovam, ki so nam pri delu pomagale ali so delo omogočile. Zahvalimo se lahko tudi mentorju in morebitnemu somentorju.

# Kazalo vsebine

<b>1</b>	<b>Uvod</b>	<b>1</b>
1.1	Elektroencefalografija . . . . .	1
1.1.1	Sistem 10-20 . . . . .	1
1.2	Povezljivost . . . . .	2
<b>2</b>	<b>Metode</b>	<b>3</b>
2.1	Razvojno okolje . . . . .	3
2.1.1	EEGLAB . . . . .	3
2.1.2	Lab streaming layer . . . . .	3
2.2	EEG Motor Movement/Imagery Dataset . . . . .	3
2.2.1	Classification learner . . . . .	4
2.3	Metode povezljivosti . . . . .	4
2.3.1	Grangerjev index vzročnosti . . . . .	4
2.3.2	Kompleksni Pearsonov korelacijski koeficient . . . . .	4
2.4	Klasifikacija . . . . .	5
2.4.1	Nevronska mreža . . . . .	5
2.5	Izbira metode povezljivosti . . . . .	6
<b>3</b>	<b>Rezultati</b>	<b>8</b>
3.1	Delitev podatkov . . . . .	8
3.2	Rezultati na MMID . . . . .	8
3.2.1	Classification learner . . . . .	8
3.3	Rezultati na lastnih podatkih . . . . .	8
3.4	Preizkus v realnem času . . . . .	9
3.5	Primerjava filtrov . . . . .	9
<b>4</b>	<b>Zaključki</b>	<b>12</b>

# Kazalo tabel

1	Natančnosti klasifikacij . . . . .	8
---	------------------------------------	---

## Kazalo slik

1	Nevronska mreža. . . . .	6
2	Primerjava območij in dolžin epoh. . . . .	7
3	Matrika zmede nevronske mreže naučene na podatkih zbirke. . . . .	9
4	Matrika zmede nevronske mreže dodatno naučene na naših podatkih. .	9
5	Primerjava klasifikacije CPCC z nevronske mreže za epoho 0-4s za različne frekvenčne pasove <i>val = eeglab – Butterworth</i> testirano za 30 ljudi * 3 serije . . . . .	10
6	Matrika zmede nevronske mreže naučene na podatkih fitriranih s filtrom z ničelno fazo. . . . .	10
7	Matrika zmede nevronske mreže naučene na podatkih fitriranih z Butterworthovim filtrom. . . . .	11

# Kazalo prilog



# Seznam kratic

*tj.* to je

*npr.* na primer

PLI phase lag Index

# 1 Uvod

Motivacija za raziskavo je bilo ugotoviti do kakšne mere je mogoča razpoznavanje gibanja v živo na osnovi analize možganske aktivnosti z EEG meritvami. Najprej smo podatke iz prosto dostopne zbirke podatkov s pomočjo knjižnice EEGLAB razdelili na nekaj različno dolgih epoh po dogodkih in jim zožili frekvenčne pasove. Iz vsake pridobljene zbirke podatkov smo pridobili matrike povezljivosti Grangerjevega indexa vzročnosti in matrike povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta. Na pridobljenih podatkih smo naučili nevronske mreže. Iz pridobljenih rezultatov smo se odločili za nadaljevanje razvoja na zbirki, ki je obetala najboljšo natančnost. Da bi omogočili delovanje v realnem času smo sami implementirali nekaj že obstoječih funkcij iz knjižnice. Posneli smo podatke na Cognionics Quick-20 in dodatno naučili nevronske mreže na naših podatkih za boljšo klasifikacijo.

## 1.1 Elektroencefalografija

Elektroencefalografija je metoda za merjenje možganske električne aktivnosti. Meri električne potenciale na površini temena ki jih deloma generira možganska aktivnost. V zadnjem stoletju so znanstveniki s pomočjo EEG pridobili vpogled v različne nevrološke bolezni. V zadnjem času pa se pojavlja interes v modeliranju eeg signalov in uporabo le teh za nadzor fizičnih naprav. EEG signali so običajno razdeljeni v območja ki odražajo različne spektralne vrhove. Ta območja so običajno določena kot delta (1-4 Hz), theta (4-8 Hz), alpha (8-13 Hz), beta (13-20 Hz), in gamma (<20 Hz). [6]

### 1.1.1 Sistem 10-20

Mednarodni sistem 10-20 standardizira mesta elektrod tako, da so te nameščene v mrežo od naziona do iniona ter od desnega do levega sluhovoda v presledkih 10 in 20 odstotkov razdalje. Vsaka elektroda je označena z črko lokacijo: T-Temporal, F-Frontal, P-Parietal, C-Central in O-Occipital, ter z črko z za elektrode na sredini glave, lihimi številkami za levo polovico glave in sodimi za desno. [1]

## 1.2 Povezljivost

Povezljivost se nananaša na vzorce nastale zaradi anatomskih povezav možganov, statistične odvisnosti ali interakcij med posameznimi deli možganov. Enote med katerimi se meri povezljivost so lahko različne: posamezni nevroni, nevronske populacije, v našem primeru pa regije možganske skorje. Možganska aktivnost je omejena s povezljivostjo, le ta pa je zato ključnega pomena za razumevanje delovanja možganov. V grobem poznamo dve vrsti povezljivosti: strukturno in funkcijsko. Strukturna povezanost se nanaša na to kako so deli možganov med seboj fizično povezani. Funkcijska povezljivost pa se nanaša na to kako različni deli možganov med seboj komunicirajo oziroma sodelujejo.[4]

Mogoče tu bolj natančno o funkcijski povezljivosti, podnaslov?

## 2 Metode

### 2.1 Razvojno okolje

Ves razvoj je potekal v programskem okolju MATLAB. Ta poleg samega programskega jezika vsebuje velik nabor že implementiranih funkcij, napredne aplikacije za strojno učenje in knjižnice ki omogočajo povezave z laboratorijskimi napravami. V njem sta ustvarjeni funkciji za računanje matrik Grangerjevega indexa vzročnosti in matrik Kompleksnega Pearsonov korelacijskega koeficienta. V njem so ustvarjene nevronske mreže in uporabljeno je za ostale klasifikatorje. Prav tako smo v njem napisali funkcijo za zajemanje podatkov iz naprave Cognionics Quick-20, funkcijo ki v realnem času razpoznavna gibanja.

#### 2.1.1 EEGLAB

EEGLAB je interaktivna matlab orodjarna, za procesiranje in obdelavo elektrofizioloških podatkov. Omogoča rereferenciranje EEG signalov, izbiro določenih elektrod, deljenje podatkov na epohe glede na dogodke in filtriranje frekvenc. Omogoča interakcijo preko uporabniškega vmesnika. Vse akcije v vmesniku se prevedejo v ukaze ki jih lahko uporabimo v svoji kodi. Pri izdelavi naloge smo največ uporabljali funkcije branja .edf datotek, filtriranja frekvenc signalov in deljanja posnetkov na manjše dele.[8]

#### 2.1.2 Lab streaming layer

Lab streaming layer je odprtokodna vmesna programska oprema ki omogoča pošiljanje, prejemanje, sinhronizacijo in snemanje tokov podatkov. Omogoča enostavno povezovanje EEG naprave z programsko opremo MATLAB. Knjižnjico je potrebno prenesti in nato zgraditi na svojem računalniku. [9]

### 2.2 EEG Motor Movement/Imagery Dataset

EEG Motor Movement/Imagery Dataset je prosto dostopna zbirka več kot 1500 eno in dve minutnih posnetkov 109 prostovoljcev ki opravljajo različne naloge. Za nas

relevantni so posnetki serij 3, 5 in 7 v katerih prostovoljci stiskajo in sproščajo levo ali desno pest. Posnetki so shranjeni v formatu EDF+ ki vsebuje posnetke EEG in oznake dogodkov. Snemanje je bilo opravljeno s frekvenco 160Hz in 64 elektrodnim sistemom EEG.[5, 2]

## 2.2.1 Classification learner

Classification learner je aplikacija v Matlabu za enostavno klasifikacijo podatkov. Podpira različne metode klasifikacije, navzkrižno validacijo in uporabo različnih podatkov za gradnjo in testiranje modela. Z njo smo lahko hitro ocenili uspešnost računanja matrik povezljivosti in primerjali delovanje različnih klasifikatorjev v primerjavi z našo nevronske mrežo.

## 2.3 Metode povezljivosti

### 2.3.1 Grangerjev index vzročnosti

Grangerjev index vzročnosti je statistična metoda za preverjanje ali ena časovna vrsta nosi informacije o drugi. Metoda je bila razvita v šestdesetih letih devetnajstega stoletja za uporabo ekonomiji.

Za dve časovni vrsti  $X_1$  in  $X_2$ , in  $p$  kot število prejšnjih vrednosti ki jih upoštevamo pri računanju, lahko izračunamo  $E_1$  in  $E_2$  ki so napake pri predvidevanju naslednje vrednosti v vrsti  $X_1$ . V kolikor je varianca vrednosti  $E_2$  manjša kot varianca vrednosti  $E_1$  lahko predvidevamo da časovna vrsta  $X_2$  nosi informacije o časovni vrsti  $X_1$

$$X_1(t) = \sum_{j=1}^p A_{1,j} X_1(t-j) + E_1(t)$$

$$X_1(t) = \sum_{j=1}^p A_{2,j} X_1(t-j) + \sum_{j=1}^p A_{3,j} X_2(t-j) + E_2(t)$$

Mogoče razlaga kaj so A-ji. Ali so pravilno zapisani?

[3]

### 2.3.2 Kompleksni Pearsonov korelacijski koeficient

Pearsonov korelacijski koeficient je najpogosteje uporabljen linearni korelacijski koeficient. Zanj smo se odločili saj v članku »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis« avtorji pokažejo da vsebuje informacije PLI in wPLI ki sta dve najbolj pogosto uporabljeni metodi povezljivosti. V praksi nam pove, v kakšni meri sta fazi dveh signalov linearno povezani.

Ker želimo opazovati faze EEG signala, ga potrebujemo pretvoriti v analitični signal ki vsebuje informacijo o fazi. Zaradi sledeče transformacije, ki je definirana samo na ozkih frekvenčnih pasovih potrebujemo signale EEG predhodno filtrirati. Analitični signal  $X_a$  kjer  $HT(X(t))$  označuje hilbertovo transformacijo signala  $X$ .

$$X_a(t) = X(t) + i \cdot HT(X(t))$$

Za računanje Kompleksnega Pearsonovega korelacijskega koeficienta v našem primer lahko uporabimo naslednjo enačbo kjer sta  $X_1$  in  $X_2$  analitična signal dolžine  $N$ .  $\overline{X_2(n)}$  pa konjugirana vrednost  $X_2(n)$

$$r(X_1, X_2) = \frac{\sum_{n=1}^N (X_1(n) \cdot \overline{X_2(n)})}{\sqrt{\sum_{n=1}^N |X_1(n)|^2} \cdot \sqrt{\sum_{n=1}^N |X_2(n)|^2}}.$$

Kaj predstavlja pika na koncu enačbe?

[7]


## 2.4 Klasifikacija

Na matrikah povezljivosti pridobljenih z metodo Kompleksnega Pearsonovega korelacijskega koeficienta iz podatkov zbirke in naših posnetkov smo izvedli več različnih klasifikacije in sicer: odločitvena drevesa, metodo k najbližjih sosedov (k-NN), logistično regresijo, podporne vektorske stroje (SVM) in nevronske mreže.

Želeli smo preizkusiti kako uspešno bi klasifikacija delovala na podatkih zbirke in kako uspešno bi delovala na naših podatkih, zato smo klasifikacijo izvajali dvakrat. Enkrat na podatkih zbirke in enkrat na naših podatkih. Ker nevronska mreža za učenje potrebuje več podatkov kot jih lahko zagotovimo iz naših posnetkov smo jo za namene klasifikacije naših posnetkov naučili na podatkih MMID in nato dodatno naučili na naših podatkih.

### 2.4.1 Nevronska mreža

Nevronska mreža je sestavljena iz vhodne plasti za slike dimenzij 19x19x1, polno povezanega sloja s 100 nevroni, Leaky ReLU sloja, dropout sloja z 50% verjetnostjo opustitve nevronov, polno povezanega sloja z 10 nevroni, GELU sloja, dropout sloja z 50% verjetnostjo opustitve nevronov, polno povezanega sloja s tremi nevroni in Softmax sloja.




Slika 1: Nevronska mreža.

## 2.5 Izbira metode povezljivosti

### Mogoče že v rezultati?

Ker je kompleksni Pearsonov korelacijski koeficient izračunan iz analitičnih signalov ga lahko definiramo samo za ozke frekvenčne pasove. Pri računanju Grangerjevega indexa vzročnosti te omejitve ni, tako da smo ga lahko računali na celotnem frekvenčnem območju do 45Hz. Prav tako se je pojavilo vprašanje koliko dolgo epoho EEG signala bomo potrebovali za uspešno klasifikacijo. Kot možnosti smo vzeli prvo sekundo, prvi dve sekundi, drugi dve sekundi in prve štiri sekunde po dogodku. Natančnost klasifikacije smo ocenili z zgoraj navedeno nevronska mrežo. Za najboljšo metodo se je izkazal kompleksni Pearsonov korelacijski koeficient na območju 13-30Hz z najdaljšimi epohami, 4s.



Slika 2: Primerjava območij in dolžin epoh.



## 3 Rezultati

### 3.1 Delitev podatkov

Za končno raziskavo smo imeli na voljo 7368 primerov stanj iz podatkovne zbirke EEG Motor Movement/Imagery Dataset. Primere stanj smo skrčili na enakomerno razporeditev, z 2456 primeri vsakega stanja. Sami smo posneli neka minut posnetkov, 186 primerov stanj od tega 62 primerov vsakega stanja. Za učenje nevronske mreže smo uporabljali množice za učenje z 75% podatkov in množice za testiranje z 25% podatkov.

### 3.2 Rezultati na MMID

#### 3.2.1 Classification learner

Z uporabo aplikacije classification learner smo testirali več načinov klasifikacije, vendar noben ni bil zelo uspešen. Najbolj uspešna je bila logistična regresija z 49%.

Metoda klasifikacije	natančnost
odločitvena drevo	40%
k-NN	41%
logistična regresija	49%
SVM	45%

Tabela 1: Natančnosti klasifikacij

Nato smo poskusili z nevronske mreže ki je dosegla 52% natančnost.

### 3.3 Rezultati na lastnih podatkih

Da bi se približali pogojem v realnem času, smo nevronske mreže dodatno naučili na naših podatkih. Zaradi različnih pogojev snemanja in natančnosti naprav na katerih so podatki snemani je natančnost klasifikacije pričakovano padla.

**Confusion Matrix**

Output Class	rest	1401 19.0%	504 6.8%	526 7.1%	57.6% 42.4%
	left	502 6.8%	1150 15.6%	621 8.4%	50.6% 49.4%
	right	553 7.5%	802 10.9%	1309 17.8%	49.1% 50.9%
		57.0% 43.0%	46.8% 53.2%	53.3% 46.7%	52.4% 47.6%
		rest	left	right	
		Target Class			

Slika 3: Matrika zmede nevronske mreže naučene na podatkih zbirke.

**Confusion Matrix**

Output Class	rest	25 13.4%	15 8.1%	16 8.6%	44.6% 55.4%
	left	15 8.1%	34 18.3%	24 12.9%	46.6% 53.4%
	right	22 11.8%	13 7.0%	22 11.8%	38.6% 61.4%
		40.3% 59.7%	54.8% 45.2%	35.5% 64.5%	43.5% 56.5%
		rest	left	right	
		Target Class			


Slika 4: Matrika zmede nevronske mreže dodatno naučene na naših podatkih.

### 3.4 Preizkus v realnem času


### 3.5 Primerjava filtrov

Knjižnica EEGLAB vsebuje samo filtre z ničelno fazo, ki filtrirajo naprej in nato nazaj po času, kar v našem primeru ni primerno saj podatke prejemamo sekvenčno, zato smo podatke filtrirali s pomočjo Butterworthovega filtra ki vsebuje stanja. Stanja nam


omogočajo filtriranje sekvenčnih podatkov saj preprečijo napako na začetku filtra kjer le ta potrebuje predpostaviti začetno staje vseh signalov 0. Ker filtra nista enakovredna saj prvi ne spreminja faz drugi pa jih zamakne, uporabljena metoda CPCC pa deluje na zamikih faz, smo izvedli dodatno testiranje, da smo preverili če pristop deluje enako učinkovito.



Slika 5: Primerjava klasifikacije CPCC z nevronske mrežo za epoho 0-4s za različne frekvenčne pasove *val = eeglab – Butterworth* testirano za 30 ljudi \* 3 serije



Slika 6: Matrika zmede nevronske mreže naučene na podatkih fitriranih s filtrom z ničelno fazo.



Slika 7: Matrika zmede nevronske mreže naučene na podatkih fitriranih z Butterworthovim filtrom.

## 4 Zaključki

# Literatura

- [1] G. H. Klem in sod. »The ten-twenty electrode system of the International Federation. The International Federation of Clinical Neurophysiology«. V: *Electroencephalogr Clin Neurophysiol Suppl* 52 (1999), str. 3–6. ISSN: 0424-8155.
- [2] Gerwin Schalk in sod. »BCI2000: a general-purpose brain-computer interface (BCI) system«. V: *IEEE Trans Biomed Eng* 51.6 (jun. 2004), str. 1034–1043. ISSN: 0018-9294. DOI: 10.1109/TBME.2004.827072.
- [3] Anil Seth. »Granger causality«. V: *Scholarpedia* 2.7 (6. jul. 2007), str. 1667. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.1667. URL: [http://www.scholarpedia.org/article/Granger\\_causality](http://www.scholarpedia.org/article/Granger_causality) (pridobljeno 16. 6. 2024).
- [4] Olaf Sporns. »Brain connectivity«. V: *Scholarpedia* 2.10 (28. okt. 2007), str. 4695. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.4695. URL: [http://www.scholarpedia.org/article/Brain\\_connectivity](http://www.scholarpedia.org/article/Brain_connectivity) (pridobljeno 16. 6. 2024).
- [5] Gerwin Schalk in sod. *EEG Motor Movement/Imagery Dataset*. 2009. DOI: 10.13026/C28G6P. URL: <https://physionet.org/content/eegmmidb/> (pridobljeno 13. 6. 2024).
- [6] Michael Nunez, Paul Nunez in Ramesh Srinivasan. »Electroencephalography (EEG): neurophysics, experimental methods, and signal processing«. V: 1. jan. 2016, str. 175–197. ISBN: 978-1-4822-2097-1. DOI: 10.13140/RG.2.2.12706.63687.
- [7] Zoran Šverko in sod. »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis«. V: *Sensors (Basel)* 22.4 (14. feb. 2022), str. 1477. ISSN: 1424-8220. DOI: 10.3390/s22041477. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8879969/> (pridobljeno 17. 6. 2024).
- [8] *EEGLAB*. URL: <https://sccn.ucsd.edu/eeglab/index.php> (pridobljeno 13. 6. 2024).
- [9] *lsl-website*. URL: <https://labstreaminglayer.org/#/> (pridobljeno 13. 6. 2024).