

UNIVERZA NA PRIMORSKEM  
FAKULTETA ZA MATEMATIKO, NARAVOSLOVJE IN  
INFORMACIJSKE TEHNOLOGIJE

Zaključna naloga

**Razpoznavanje gibanja na osnovi elektroencefalografije**

(Movement recognition based on electroencephalography)

Ime in priimek: Marko Rozman

Študijski program: Računalništvo in informatika

Mentor: doc. dr. Peter Rogelj

**Koper, Julij 2024**

## Ključna dokumentacijska informacija

Ime in PRIIMEK: Marko ROZMAN

Naslov zaključne naloge: Razpoznavanje gibanja na osnovi elektroencefalografije

Kraj: Koper

Leto: 2024

Število listov: 33

Število slik: 15

Število tabel: 2

Število referenc: 15

Mentor: doc. dr. Peter Rogelj

Ključne besede: elektroencefalografija, Grangerjev indeks vzročnosti, kompleksni Pearsonov korelacijski koeficient, nevronska mreža, razvrščanje

### Izvleček:

Namen naloge je preveriti zmožnost razpoznavanja gibanja na osnovi ocenjene možganske povezljivosti, temelječe na podatkih elektroencefalografije. Gibanje smo razpoznavali iz podatkov EEG Motor Movement/Imagery Dataset in podatkov, ki smo jih posneli sami na napravi Cognionics Quick-20. Iz posnetkov smo z Grangerjevim indeksom vzročnosti in kompleksnim Pearsonovim korelacijskim koeficientom izračunali matrike povezljivosti, ki smo jih nato razvrstili z različnimi algoritmi, vključno z nevronskimi mrežami. Naši rezultati kažejo, da je gibanje mogoče razvrstiti z značilkami, ki izhajajo iz možganske povezljivosti. Ob uporabi optimalnega frekvenčnega pasu, ki je v našem primeru 13–20 Hz, je razvrščanje bolj točno z uporabo značilk, pridobljenih z uporabo kompleksnega Pearsonovega korelacijskega koeficienta, čeprav ta, za razliko od Grangerjevega indeksa vzročnosti, ne podaja informacije o usmerjenosti povezav.

## Key words documentation

Name and SURNAME: Marko ROZMAN

Title of final project paper: Movement recognition based on electroencephalography

Place: Koper

Year: 2024

Number of pages: 33

Number of figures: 15

Number of tables: 2

Number of references: 15

Mentor: Assist. Prof. Peter Rogelj, PhD

Keywords: electroencephalography, Granger causality index, complex Pearson correlation coefficient, neural network, classification

### **Abstract:**

The purpose of our research is to evaluate the ability to recognize movement based on estimated brain connectivity derived from electroencephalography data. We classified movements from the EEG Motor Movement/Imagery Dataset and data we recorded ourselves using the Cognionics Quick-20 device. We used Granger causality index and the complex Pearson correlation coefficient to calculate connectivity matrices from the recordings, which we then classified using various algorithms, including neural networks. Our results show that movement can be recognized using features derived from brain connectivity. By using the optimal frequency band, which in our case was 13-20 Hz, classification is more accurate with features obtained using the complex Pearson correlation coefficient, even though it does not provide information about the directionality of connections as the Granger causality index does.

## Zahvala

Iskreno se zahvaljujem svojemu mentorju, doc. dr. Petru Roglju, za neprecenljivo podporo in vodenje pri pisanju diplomske naloge. Njegova strokovna pomoč pri izbiri metod, implementaciji ter pisanju je bila ključnega pomena na vsakem koraku. Hvaležen sem za priložnost dela s fizično napravo in za redne konzultacije ob sredah, ki so pripomogle k jasnosti in uspešnosti mojega dela.

Prav tako se iz srca zahvaljujem prijateljem in družini za njihovo neomajno podporo in spodbudo skozi celoten proces.

# Kazalo vsebine

<b>1</b>	<b>Uvod</b>	<b>1</b>
1.1	Elektroencefalografija . . . . .	2
1.1.1	Mednarodni sistem 10-20 postavitve elektrod . . . . .	3
1.1.2	Cognionics Quick-20 . . . . .	5
1.2	Možganska povezljivost . . . . .	5
<b>2</b>	<b>Podatki in metode</b>	<b>7</b>
2.1	Razvojno okolje MATLAB . . . . .	7
2.1.1	EEGLAB . . . . .	8
2.1.2	Lab Streaming Layer . . . . .	8
2.1.3	Classification Learner . . . . .	9
2.2	Podatkovna zbirka EEG Motor Movement/Imagery Dataset . . . . .	10
2.3	Metode povezljivosti . . . . .	10
2.3.1	Grangerjev indeks vzročnosti . . . . .	11
2.3.2	Kompleksni Pearsonov korelacijski koeficient . . . . .	11
2.4	Razvrščanje . . . . .	12
2.4.1	Razvrščanje v okolju Classification learner . . . . .	12
2.4.2	Razvrščanje z lastno nevronske mrežo . . . . .	12
<b>3</b>	<b>Rezultati</b>	<b>14</b>
3.1	Točnost razvrščanja . . . . .	14
3.2	Delitev podatkov . . . . .	14
3.3	Rezultati na MMID . . . . .	14
3.3.1	Izbira metode povezljivosti . . . . .	14
3.3.2	Izbira uporabljenih filtrov . . . . .	16
3.3.3	Rezultati z okoljem Classification Learner . . . . .	17
3.3.4	Rezultati z uporabo lastne nevronske mreže . . . . .	17
3.4	Rezultati na lastnih podatkih . . . . .	21
3.5	Sprotno razpoznavanje . . . . .	21
<b>4</b>	<b>Zaključki</b>	<b>23</b>

# Kazalo tabel

1	Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podatkov MMID. . . . .	10
2	Točnost vseh testiranih metod razvrščanja v aplikaciji Clasification Learner. . . . .	18

## Kazalo slik

1	Frekvenčna območja EEG signala. . . . .	2
2	Mednarodni sistem 10-20 postavitve elektrod. . . . .	3
3	Mednarodni sistem 10-10 postavitve elektrod. . . . .	4
4	EEG naprava Cognionics Quick-20. . . . .	5
5	Programsko okolje MATLAB. . . . .	7
6	Orodjarna EEGLAB. . . . .	8
7	Aplikacija Classification learner. . . . .	9
8	Arhitektura lastne nevronske mreže. . . . .	13
9	Točnost razvrščanja po frekvenčnih območjih in dolžini epoh. . . . .	15
10	Točnost razvrščanja glede na tip filtra in frekvenčno območje. . . . .	16
11	Matriki zmede nevronske mreže za frekvenčno območje beta. . . . .	17
12	Matrika zmede metode Quadratic SVM. . . . .	19
13	Matrika zmede lastne nevronske mreže. . . . .	20
14	Matrika zmede dodatno naučene nevronske mreže. . . . .	21
15	Prikaz sprotnega razpoznavanja . . . . .	22

## Seznam kratic

<i>EEG</i>	elektroencefalografija
<i>MMID</i>	Motor Movement/Imagery Dataset
<i>PLI</i>	phase lag index
<i>wPLI</i>	weighted phase lag index
<i>k - NN</i>	k nearest neighbours
<i>SVM</i>	support vector machine
<i>CPCC</i>	complex Pearson correlation coefficient
<i>GC</i>	Granger causality




# 1 Uvod

Motivacija za raziskavo je bila ugotoviti, do kakšne mere je mogoče razpoznavanje gibanja v živo na osnovi analize možganske aktivnosti z meritvami elektronecefalografije (EEG). Najprej smo podatke iz prosto dostopne zbirke podatkov s pomočjo knjižnice EEGLAB razdelili na nekaj različno dolgih epoh po dogodkih in jim zožili frekvenčne pasove. Iz vsake pridobljene zbirke podatkov smo izračunali matrike povezljivosti Grangerjevega indeksa vzročnosti in matrike povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta. Na pridobljenih podatkih smo naučili nevronske mrežo. Iz pridobljenih rezultatov smo se odločili za nadaljevanje razvoja na zbirki, ki je obetala najboljšo točnost. Da bi omogočili delovanje v realnem času smo implementirali nekaj že obstoječih funkcij iz knjižnice. Posneli smo podatke na napravi Cognionics Quick-20 in dodatno naučili nevronske mrežo na naših podatkih za boljše razvrščanje.

## 1.1 Elektroencefalografija


Elektroencefalografija je metoda za merjenje možganske električne aktivnosti. Meri električne potenciale na površini temena, ki jih deloma generira možganska aktivnost. V zadnjem stoletju so znanstveniki s pomočjo EEG pridobili vpogled v različne nevrološke bolezni. V zadnjem času pa se pojavlja interes za modeliranje EEG signalov in uporabo le-teh za nadzor fizičnih naprav (ang. Brain-Computer Interfacing). EEG signali so običajno razdeljeni v frekvenčna območja, ki odražajo različne spektralne vrhove in jih povezujemo z različnimi možganskimi procesi. Ta območja (Slika 1) so običajno določena kot delta (1-4 Hz), theta (4-8 Hz), alpha (8-13 Hz), beta (13-20 Hz), in gamma ( $>20$  Hz). [7]




Slika 1: Prvih 8 sekund EEG signala elektrode C3, osebe S001 serije R03. Od zgoraj navzdol po področjih: vsa skupaj, delta, theta, alpha, beta, gamma.

### 1.1.1 Mednarodni sistem 10-20 postavitve elektrod

Mednarodni sistem 10-20 (slika 2) standardizira mesta elektrod tako, da so te nameščene v mrežo od naziona do iniona ter od desnega do levega sluhovoda v presledkih 10 in 20 odstotkov razdalje. Vsaka elektroda je označena s črko lokacije: *T* -Temporal, *F* -Frontal, *P* -Parietal, *C* -Central in *O* -Occipital, ter s črko *Z* za elektrode na sredini glave, lihimimi številkami za levo polovico glave in sodimi za desno. [1] Poleg mednarodnega sistema 10-20 za postavitev elektrod obstajajo tudi drugi sistemi, kot je na primer mednarodni sistem 10-10 postavitve elektrod. Podatki, snemani v živo, so bili pridobljeni po mednarodnem sistemu 10-20, medtem ko je bila podatkovna zbirka, uporabljena za učenje, snemana po prilagojenem mednarodnem sistemu 10-10 postavitve elektrod.



Slika 2: Prikaz postavitve elektrod po mednarodnem sistemu 10-20. Nameščene v mrežo od naziona do iniona in od levega do desnega sluhovoda v presledkih 10 in 20 odstotkov. [12]



Slika 3: Prikaz postavitve elektrod po mednarodnem sistemu 10-10. [13]

### 1.1.2 Cognionics Quick-20

Cognionics Quick-20 (slika 4) je brezžična EEG naprava s suhimi elektrodami za raziskovalne namene. Ima 21 elektrod postavljenih po mednarodnem sistemu 10-20 za postavitve elektrod. Naprava je suhega tipa, kar pomeni, da pri uporabi elektrode gel ni potreben. Suhi tipi naprav so v primerjavi z mokrimi enostavnejši in udobnejši za uporabo ter omogočajo hitro nastavitve. Naprava je brezžična, z računalnikom jo povežemo preko USB vmesnika. [10]



Slika 4: EEG naprava Cognionics Quick-20. [9]

## 1.2 Možganska povezljivost

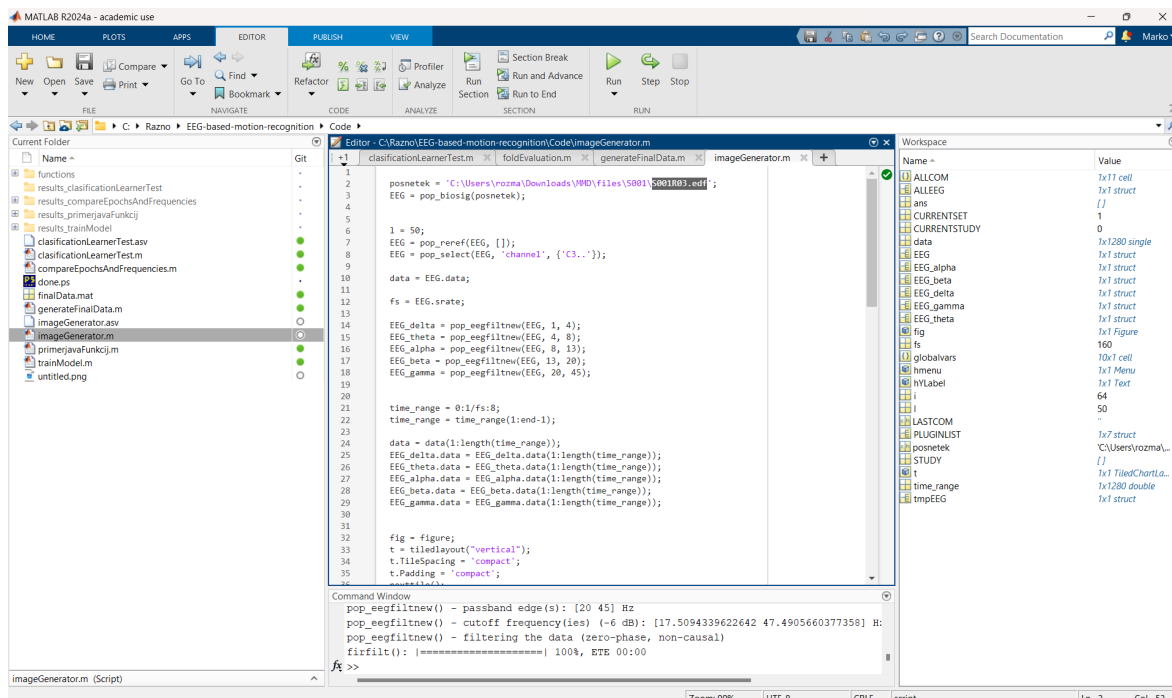
Možganska povezljivost se nanaša na vzorce, nastale zaradi anatomskih povezav možganov, statistične odvisnosti ali interakcij med posameznimi deli možganov. Enote, med katerimi se meri povezljivost, so lahko različne: posamezni nevroni, nevronske populacije, ali pa kot v našem primeru regije možganske skorje. Možganska aktivnost je omejena s povezljivostjo, le-ta pa je zato ključnega pomena za razumevanje delovanja možganov. V grobem poznamo dve vrsti povezljivosti: strukturno in funkcijsko. Strukturna povezanost se nanaša na anatomsko povezanost različnih delov možganov. Funkcijska povezljivost pa se nanaša na to kako različni deli možganov med seboj komunicirajo oziroma sodelujejo.[4] Funkcijsko povezljivost lahko nadaljnjo delimo na

usmerjeno in neusmerjeno. V našem primeru je metoda Grangerjevega indeksa vzročnosti (GC) usmerjena, saj je vpliv elektrode  $A$  na elektrodo  $B$  drugačen kot vpliv elektrode  $B$  na elektrodo  $A$ . Metoda kompleksnega Pearsonovega korelacijskega koeficienta (CPCC) pa je neusmerjena, saj nam njegova vrednost pove le o povezanosti para elektrod zato se pri njej ne ugotavlja smeri vpliva. V izrazu Grangerjev indeks vzročnosti je vzorčnost zavajajoč termin, saj nam Grangerjev indeks vzročnosti nakazuje le, da en signal vpliva na drugega vendar sta lahko v določenih primerih obe meritvi odvisni od nečesa tretjega.

## 2 Podatki in metode

### 2.1 Razvojno okolje MATLAB


Ves razvoj je potekal v programskem okolju MATLAB. Ta poleg samega programskega jezika vsebuje tudi širok nabor že implementiranih funkcij, napredne aplikacije za strojno učenje in knjižnice, ki omogočajo povezave z laboratorijskimi napravami. V njem sta ustvarjeni funkciji za računanje matrik Grangerjevega indeksa vzročnosti in matrik kompleksnega Pearsonovega korelacijskega koeficienta, prav tako pa so v njem ustvarjene nevronske mreže. Programsko okolje MATLAB se uporablja tudi za ostala razvrščanja, funkcijo za zajemanje podatkov iz naprave Cognionics Quick-20 ter funkcijo, ki v realnem času razpoznava gibanje. [15]



Slika 5: Programsko okolje MATLAB. Od leve proti desni: podokno z datotekami, podokno s kodo, podokno s spremenljivkami. Zgoraj zavihki za orodjarno, aplikacije in prikaz podatkov.

### 2.1.1 EEGLAB

EEGLAB je interaktivna MATLAB orodjarna, za procesiranje in obdelavo elektrofizioloških podatkov. Omogoča rereferenciranje EEG signalov, izbiro določenih elektrod, deljenje podatkov na epohe glede na dogodke in filtriranje frekvenc. Omogoča interakcijo preko uporabniškega vmesnika. Vse akcije v vmesniku se prevedejo v ukaze. Grafični vmesnik je uporaben za enostavne analize. Za avtomatizacijo pa njegove funkcije uporabimo v svoji kodi z ustreznimi ukazi. Pri izdelavi naloge smo največ uporabljali funkcije branja .edf datotek, filtriranja frekvenc signalov in deljenja posnetkov na manjše dele. [11]



Slika 6: Orodjarna EEGLAB. Zgoraj: zavihki za delo z datotekami, urejanje, orodja, prikaz podatkov, delo z zbirkami podatkov in pomoč. Naložen podatkovni niz dolžine 124 sekund s 30 dogodki.


### 2.1.2 Lab Streaming Layer

Lab Streaming Layer je odprtokodna vmesna programska oprema, ki omogoča pošiljanje, prejemanje, sinhronizacijo in snemanje tokov podatkov znotraj lokalnega omrežja. Med drugim je na voljo v obliki MATLAB knjižnice, ki omogoča preprosto integracijo EEG naprav s programsko opremo MATLAB. Knjižnico je potrebno prenesti in nato zgraditi na svojem računalniku. [14]



### 2.1.3 Classification Learner

Classification Learner je aplikacija v okolju MATLAB za enostavno razvrščanje podatkov. Podpira različne metode razvrščanja, prečno preverjanje in uporabo različnih podatkov za gradnjo in testiranje modela. Aplikacija podpira razvrščanje podatkov iz dvodimenzionalnih matrik, kjer vrstice ali stolpci predstavljajo spremenljivke. Oznake podatkov lahko podamo kot določeno vrstico ali stolpec matrike, lahko pa tudi v ločeni spremenljivki. Zaradi omejitev aplikacije smo pred razvrščanjem matrike povezljivosti pretvorili v vektorje in te združili v matriko podatkov. Z aplikacijo smo lahko enostavno primerjali delovanje različnih razvrščanj v primerjavi z lastno nevronske mrežo, ki smo jo izvedli izven aplikacije Classification Learner.



Slika 7: Aplikacija Classification learner. Na levi strani podokno z različnimi metodami razvrščanja, na sredini prikaz podrobnosti izbrane metode. Zgoraj zavihki za učenje, testiranje in razlago.

## 2.2 Podatkovna zbirka EEG Motor Movement/Imagery Dataset

EEG Motor Movement/Imagery Dataset (MMID) je prosto dostopna zbirka več kot 1500 posnetkov 109 prostovoljcev, ki so dolgi po eno in dve minuti. Zbirka za vsakega prostovoljca vsebuje dva izhodiščna posnetka in po tri posnetke opravljanja štirih različnih nalog: stiskanje in sproščanje leve ali desne pesti (naloga 1), namišljeno stiskanje in sproščanje leve ali desne pesti (naloga 2), stiskanje in sproščanje obeh pesti ali obeh stopal (naloga 3), namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal (naloga 4). Za nas relevantni so posnetki serij 3, 7 in 11, v katerih prostovoljci opravljajo prvo nalogo. Posnetki so shranjeni v formatu EDF+, ki vsebuje posnetke EEG in oznake dogodkov. Snemanje je bilo opravljeno s sistemom BCI2000 s 64 elektrodami postavljenimi po mednarodnem sistemu 10-10 (slika 3) brez elektrod Nz, F9, F10, FT9, FT10, A1, A2, TP9, TP10, P9, in P10. [2, 5]

Številka serije	Naloga	Opis naloge
1	izhodišče	odprte oči
2	izhodišče	zaprte oči
3	naloga 1	stiskanje in sproščanje leve ali desne pesti
4	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
5	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
6	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
7	naloga 1	stiskanje in sproščanje leve ali desne pesti
8	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
9	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
10	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
11	naloga 1	stiskanje in sproščanje leve ali desne pesti
12	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
13	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
14	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal

Tabela 1: Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podatkov MMID.

## 2.3 Metode povezljivosti

Metode povezljivosti se uporabljajo za analizo delovanja možganov, saj nam v nasprotju z direktnim razvrščanjem EEG signalov omogočajo identifikacijo specifičnih vzorce, s

čimer pridobimo globlji vpogled v delovanje možganov.

### 2.3.1 Grangerjev indeks vzročnosti

Grangerjev indeks vzročnosti je statistična metoda za preverjanje, ali ena časovna vrsta nosi informacije o drugi. Metoda je bila razvita v šestdesetih letih devetnajstega stoletja za uporabo ekonomiji. [6]

Za dve časovni vrsti,  $X_1$  in  $X_2$ , ter red  $p$  (ang. order) kot število prejšnjih vrednosti, ki jih upoštevamo pri računanju, lahko izračunamo  $E_1$  in  $E_2$  ki so napake pri predvidevanju naslednje vrednosti v vrsti  $X_1$ .  $A_1$ ,  $A_2$  in  $A_3$  so koeficienti avto-regresivnega modela. [3]

$$X_1(t) = \sum_{j=1}^p A_{1,j} X_1(t-j) + E_1(t)$$

$$X_1(t) = \sum_{j=1}^p A_{2,j} X_1(t-j) + \sum_{j=1}^p A_{3,j} X_2(t-j) + E_2(t)$$

V kolikor je varianca vrednosti  $E_2$  manjša kot varianca vrednosti  $E_1$  lahko predvidamo, da časovna vrsta  $X_2$  nosi informacije o časovni vrsti  $X_1$ . [3]

Sam indeks vzročnosti pa izračunamo po formuli:

$$GC = \log \left( \frac{\text{varianca}(E_1)}{\text{varianca}(E_2)} \right)$$

### 2.3.2 Kompleksni Pearsonov korelacijski koeficient

Pearsonov korelacijski koeficient je najpogosteje uporabljen linearni korelacijski koeficient. Zanj smo se odločili zaradi članka »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis«, v katerem avtorji pokažejo da vsebuje informacije Phase Locking Value (PLV) in Weighted Phase Lag Index (wPLI), ki sta dve najbolj pogosto uporabljeni metodi poveztivosti. V praksi nam kompleksni Pearsonov korelacijski koeficient pove, v kakšni meri sta fazi dveh signalov linearno povezani. [8]

Ker želimo opazovati faze EEG signala, ga moramo najprej pretvoriti v analitični signal, ki vsebuje informacijo o fazi. Da je informacija o fazi bolj verodostojna in informativna, mora biti signal omejen na ožje frekvenčno področje, kar dosežemo s predhodnim filtriranjem. Analitični signal  $X_a$  kjer  $HT(X(t))$  označuje Hilbertovo transformacijo signala  $X$ . [8]

$$X_a(t) = X(t) + i \cdot HT(X(t))$$

Za računanje Kompleksnega Pearsonovega korelacijskega koeficienta v našem primeru lahko uporabimo naslednjo enačbo, kjer sta  $X_1$  in  $X_2$  analitična signal dolžine

$N$ ,  $\overline{X_2(n)}$  pa konjugirana vrednost  $X_2(n)$  [8]

$$r(X_1, X_2) = \frac{\sum_{n=1}^N (X_1(n) \cdot \overline{X_2(n)})}{\sqrt{\sum_{n=1}^N |X_1(n)|^2} \cdot \sqrt{\sum_{n=1}^N |X_2(n)|^2}}$$

## 2.4 Razvrščanje


Želeli smo preizkusiti, kako uspešno bi razvrščanje delovalo na podatkih zbirke in kako uspešno bi delovalo na naših podatkih, zato smo razvrščanja izvajali dvakrat - enkrat na podatkih zbirke in enkrat na naših podatkih. Ker nevronska mreža za učenje potrebuje več podatkov, kot jih lahko zagotovimo iz naših posnetkov, smo jo za namene razvrščanja naših posnetkov najprej naučili na podatkih MMID in nato dodatno še na naših podatkih.

### 2.4.1 Razvrščanje v okolju Classification learner

Na matrikah povezljivosti, pridobljenih iz podatkov zbirke in naših posnetkov, smo izvedli več različnih vrst razvrščanja, že implementiranega v aplikaciji Clasification learner in sicer: odločitvena drevesa, metodo k najbližjih sosedov (k-NN), logistično regresijo, podporne vektorske stroje (SVM), ansabelske metode in nevronske mreže.

### 2.4.2 Razvrščanje z lastno nevronske mreže

Za lastno implementacijo nevronske mreže smo se odločili, saj nam ta nudi možnost enostavnejše nadaljnje analize razlogov za klasifikacijo. Nevronska mreža je sestavljena iz vhodne plasti dimenzij 19x19x1 za dvodimenzionalne podatke, kakršne so matrike povezljivosti, polno povezane plasti s 100 nevroni, Leaky ReLU (usmerjena linearna enota) plasti, dropout (izpust) plasti s 50% verjetnostjo izpustitve nevronov, polno povezane plasti z 10 nevroni, GELU plasti, dropout (izpust) plasti s 50% verjetnostjo izpustitve nevronov, polno povezane plasti s tremi nevroni in softmax plasti. Mreža je realizirana z pomočjo MATLAB orodjarne Deep Learning Toolbox.



Slika 8: Arhitektura lastne nevronske mreže v MATLAB aplikaciji Deep Network Designer. Od zgoraj navzdol: plast za dvodimenzionalne podatke, polno povezana plast, Leaky ReLU (usmerjena linearna enota), dropout (izpust), polno povezana plast, GELU, dropout (izpust), polno povezana plast in Softmax.

## 3 Rezultati

### 3.1 Točnost razvrščanja

Pri interpretaciji točnosti razvrščanja stanj je potrebno upoštevati, da razvrščamo tri različna stanja, zato so že rezultati okoli 50% bistveno nad nivojem naključnosti, ki je v primeru treh različnih stanj 33%.

### 3.2 Delitev podatkov


Za končno raziskavo smo izbrali posnetke serij 3, 7 in 11 iz MMID. Vsaka serija vsebuje 109 posnetkov, vsak posnetek 30 primerov stanj, vse skupaj smo jih pridobili 9854. Primere stanj smo skrčili na enakomerno razporeditev z 2456 primeri vsakega stanja. Sami smo posneli nekaj minut posnetkov. Posneli smo vsega skupaj 250 primerov stanj, ki smo jih skrčili na enakomerno razporeditev, 62 primerov vsakega stanja. Za učenje nevronske mreže smo uporabljali množice za učenje s 75% podatkov in množice za testiranje s 25% podatkov. Podatki so bili naključno razporejeni med učno in testno množico. Ker smo podatke delili naključno, se lahko različni posnetki stanj istega prostovoljca pojavijo v učni in testni množici. Pri dodatnem učenju mreže smo uporabili posnetke ene osebe za učenje in testiranje. To skupaj pomeni, da sistem ne deluje medosebno.

### 3.3 Rezultati na MMID

Za izbiro metode povezljivosti, načina filtriranja, dolžine epohe in frekvenčnega pasu smo uporabili podatkovno zbirko MMID.


#### 3.3.1 Izbira metode povezljivosti

Ker je kompleksni Pearsonov korelacijski koeficient izračunan iz analitičnih signalov, ga lahko definiramo samo za ozke frekvenčne pasove. Pri računanju Grangerjevega indeksa vzročnosti te omejitve ni, zato smo ga lahko računali na celotnem frekvenčnem območju do 45Hz. Prav tako se je pojavilo vprašanje kako dolgo epoho EEG signala



Slika 9: Točnost razvrščanja po frekvenčnih območjih in dolžini epoh za CPCC in GC. Od zgoraj navzdol: CPCC po pasovih delta, theta, alpha, beta in gamma. Spodnja vrstica: Grangerjev indeksa vzorčnosti. Epohe od leve proti desni: prva sekunda, prvi dve sekundi, drugi dve sekundi, prve štiri sekunde.

bomo potrebovali za uspešno razvrščanje. Kot možnosti smo vzeli prvo sekundo, prvi dve sekundi, drugi dve sekundi in prve štiri sekunde po dogodku. Točnost razvrščanja smo ocenili z zgoraj navedeno nevronske mrežo. Za najboljšo metodo se je izkazal kompleksni Pearsonov korelacijski koeficient na območju 13-20 Hz z najdaljšimi epohami, 4s. Celotno območje primerjav je razvidno iz slike 9.



Slika 10: Primerjava točnosti razvrščanja glede na tip filtra. Uporabljena metoda CPCC za epoko prvih štirih sekund za frekvenčne pasove delta, theta, alpha, beta in gamma. Razvrščanje z zgoraj navedeno nevronske mreže. Modra predstavlja Butterworthov filter, oranžna predstavlja filter z ničelno fazo.

### 3.3.2 Izbira uporabljenih filtrov

Knjižnica EEGLAB vsebuje samo filtre z ničelno fazo, ki filtrirajo naprej in nato nazaj po času, kar v našem primeru ni primerno, saj podatke prejemamo sekvenčno. Filtrov z ničelno fazo ni mogoče uporabiti v realnem času. Podatke smo želeli filtrirati s pomočjo Butterworthovega filtra, ki vsebuje stanja. Stanja nam omogočajo filtriranje sekvenčnih podatkov saj preprečijo napako na začetku filtra kjer le-ta potrebuje predpostaviti začetno stajanje vseh signalov 0. Ker filtra nista enakovredna, saj prvi ne spreminja faz drugi pa jih zamakne, uporabljena metoda CPCC pa deluje na zamikih faz, smo izvedli dodatno testiranje, da bi preverili ali pristop deluje enako učinkovito. Razvrščanje matrik, pridobljenih z Butterworthovim filtrom (slika 11b) v primerjavi z filtrom z ničelno fazo (slika 11a) je bilo primerljivo točno za frekvenčni pas beta (slika 10) iz česar lahko sklepamo, da je filtriranje z Butterworthovim filtrom primerno.



		EEGLAB						Butterworth			
Output Class	rest	425 21.2%	117 5.8%	128 6.4%	63.4% 36.6%	rest		442 22.1%	122 6.1%	161 8.0%	61.0% 39.0%
	left	145 7.2%	374 18.7%	285 14.2%	46.5% 53.5%	left		111 5.5%	355 17.7%	238 11.9%	50.4% 49.6%
	right	98 4.9%	117 8.8%	255 12.7%	48.1% 51.9%	right		115 5.7%	191 9.5%	269 13.4%	46.8% 53.2%
		63.6% 36.4%	56.0% 44.0%	38.2% 61.8%	52.6% 47.4%			66.2% 33.8%	53.1% 46.9%	40.3% 59.7%	53.2% 46.8%
		Target Class						Target Class			
		rest	left	right				rest	left	right	

Slika 11: Matriki zmede nevronske mreže, naučene na podatkih, filtriranih s filtrom z ničelno fazo (levo) in Butterworthovim filtrom (desno). Uporabljena metoda CPCC za epoko prvih štirih sekund za frekvenčni pas beta. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: stanje mirovanja, skrčena leva pest, skrčena desna pest.

### 3.3.3 Rezultati z okoljem Classification Learner


Z uporabo aplikacije Classification Learner smo testirali več načinov razvrščanja. Iz rezultatov predstavljenih v tabeli 2 lahko razberemo, da so se za najbolj uspešne izkazale metode podpornih vektorjev (SVM), vendar so te metode računsko zahtevne, kar otežuje izvedbo v realnem času. Dober kandidat bi lahko bila odločitvena drevesa, saj so enostavna za učenje in interpretacijo, vendar so le ta dosegla 41% točnost. Nevronske mreže ki jih podpira aplikacija so enostavne, vendar pa je njihova interpretacija težja. Dosegle so 49% točnost.

### 3.3.4 Rezultati z uporabo lastne nevronske mreže


Nato smo poskusili z zgoraj navedeno nevronske mrežo, ki razvršča matrike povezlivosti. Mreža je dosegla enako točnost kot metode iz aplikacije Classification Learner in sicer 52%. Če primerjamo matriko zmede nevronske mreže z matriko zmede metode SVM (sliki 13 in 12), opazimo, da obe metodi bolj natančno razlikujeta stanje mirovanja od obeh stanj gibanja, medtem ko je razlikovanje med stanji gibanja med seboj manj natančno.

vrsta razvrščanja	metoda	točnost [%]
SVM	Quadratic SVM	53
SVM	Linear SVM	53
SVM	Medium Gaussian SVM	53
Ensemble	Subspace Discriminant	53
SVM	Cubic SVM	52
Kernel	SVM Kernel	52
Kernel	Logistic Regression Kernel	52
SVM	Coarse Gaussian SVM	50
Efficient Logistic Regression	Efficient Logistic Regression	49
Neural Network	Wide Neural Network	49
Neural Network	Medium Neural Network	47
Efficient Linear SVM	Efficient Linear SVM	46
Neural Network	Trilayered Neural Network	45
Neural Network	Bilayered Neural Network	45
Naive Bayes	Kernel Naive Bayes	45
Neural Network	Narrow Neural Network	45
Ensemble	Bagged Trees	44
KNN	Coarse KNN	44
Ensemble	Boosted Trees	43
Ensemble	RUSBoosted Trees	42
Tree	Medium Tree	41
Tree	Fine Tree	41
KNN	Cosine KNN	41
Tree	Coarse Tree	41
KNN	Medium KNN	40
KNN	Weighted KNN	40
Ensemble	Subspace KNN	40
KNN	Cubic KNN	40
KNN	Fine KNN	38
SVM	Fine Gaussian SVM	37

Tabela 2: Točnost vseh testiranih metod razvrščanja v aplikaciji Clasification Learner.



Slika 12: Matrika zmede metode Quadratic SVM. V poljih vidno število stanj. Od zgoraj navzdol: stanje mirovanja, skrčena leva pest, skrčena desna pest.



Slika 13: Matrika zmede lastne nevronske mreže. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: stanje mirovanja, skrčena leva pest, skrčena desna pest.

		Confusion Matrix			
Output Class	rest	<b>25</b> 13.4%	<b>15</b> 8.1%	<b>16</b> 8.6%	44.6% 55.4%
	left	<b>15</b> 8.1%	<b>34</b> 18.3%	<b>24</b> 12.9%	46.6% 53.4%
	right	<b>22</b> 11.8%	<b>13</b> 7.0%	<b>22</b> 11.8%	38.6% 61.4%
		40.3% 59.7%	54.8% 45.2%	35.5% 64.5%	43.5% 56.5%
		rest	left	right	
		Target Class			

Slika 14: Matrika zmede nevronske mreže dodatno naučenih na naših podatkih.

### 3.4 Rezultati na lastnih podatkih

Da bi se približali delovanju v realnem času, smo nevronske mreže dodatno naučili na naših podatkih. Zaradi različnih pogojev snemanja in natančnosti naprav, na katerih so podatki bili posneti, točnost razvrščanja pričakovano padla. Dosegli smo 43% točnost. Ker nimamo velikega števila posnetkov smo uporabili petkratno prečno preverjanje.

### 3.5 Sprotno razpoznavanje

Po razvoju pristopov na zbirkah podatkov smo implementirali sprotno razpoznavanje. Za prenos podatkov iz naprave Quick-20 v okolje MATLAB smo uporabili programsko opremo Lab Streaming Layer. V okolju MATLAB smo podatke združevali in iz njih vsako sekundo izračunali matriko povezljivosti z metodo CPCC za frekvenčno območje beta, filtrirano z Butterworthovim filtrom. Matriko povezljivosti smo razvrstili in rezultat razvrščanja izpisali na zaslon. Na natančnost sprotnega razvrščanja matrik



Slika 15: Prikaz sprotnega razpoznavanja. Dodan izpis razvrščanja iz okolja MATLAB.

povezljivosti ene osebe vpliva veliko dejavnikov. Nanj vpliva razpoloženje osebe, namestitev naprave, sam dogodek, ki ga razvrščamo, pa tudi motnje v okolju, ki vplivajo na osebo in napravo. Točnosti razvrščanj nismo natančno izmerili, ocenjujemo pa, da je nižja od tiste, ki smo jo dosegli na prej posnetih podatkih. Kljub temu je iz rezultatov razvidno, da je klasifikacija gibanja v realnem času mogoča.

## 4 Zaključki

V nalogi smo uspešno razpoznali gibanje iz EEG signalov, tako iz podatkovne zbirke MMID, posnete po mednarodnem sistemu 10-10, kot tudi iz podatkov, posnetih na napravi Cognionics Quick-20. Posnete signale smo obdelali z različnimi pristopi. Signale smo rereferencirali, filtrirali s filtrom z ničelno fazo in Butterworthovim filtrom na običajna območja zanimanja pri analizi EEG signalov. Nato smo signale razdelili na različno dolge epohe in izbrali najustreznejše. Obdelane signale smo pretvorili v matrike povezljivosti s pomočjo Grangerjevega indeksa vzročnosti in kompleksnega Pearsonovega korelacijskega koeficienta. Pridobljene matrike smo razvrstili z aplikacijo Clasification Learner in z nevronske mreže, ki smo jo implementirali sami. Dosegli smo zadovoljive točnosti na podatkih MMID in podatkih, posnetih z napravo Cognionics Quick-20. Metode, ki smo jih uporabljali, omogočajo nadaljnjo analizo, ki lahko prispeva k boljšemu razumevanju možganskih aktivnosti kot direktnega razvrščanja signalov. Z uporabo kompleksnega Pearsonovega korelacijskega koeficienta smo pokazali, da je razpoznavanje gibanja mogoče iz krajših epoh območja beta. Ugotovili smo, da kompleksni Pearsonov korelacijski koeficient zagotavlja boljšo metodo za izračun povezljivosti kot tradicionalno uporabljeni Grangerjev indeks vzročnosti. Za delo v realnem času smo sami implementirali in ocenili primernost filtrov, ki jih knjižnica EEGLAB ne podpira. Pokazali smo, da je najustreznejše sprotno razvrščanje z metodo povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta.

Glavne omejitve, ki nam onemogočajo še točnejše razvrščanje z uporabljenimi metodami, so omejena velikost posnetkov in omejena natančnost naprav EEG. Prav tako naloga vsebuje omejitev pri učenju klasifikatorjev, saj sistema nismo preizkusili pri razvrščanju EEG signalov oseb, na čigar signalih klasifikator ni bil naučen. Točnost sprotnega razvrščanja signalov ene osebe pa je dodatno omejena z njenim razpoložanjem.

Razpoznavanje gibanja iz signalov EEG ima potencialne aplikacije v medicini, zlasti pri razvoju sistemov za nadzor protez in rehabilitacijskih naprav. Metode povezljivosti, uporabljene v nalogi, pa nam lahko poglobijo razumevanje možganske aktivnosti med različnimi fizičnimi nalogami.

# Literatura

- [1] G. H. Klem in sod. »The Ten-Twenty Electrode System of the International Federation. The International Federation of Clinical Neurophysiology«. V: *Electroencephalography and Clinical Neurophysiology. Supplement* 52 (1999), str. 3–6. ISSN: 0424-8155. pmid: 10590970.
- [2] Gerwin Schalk in sod. »BCI2000: A General-Purpose Brain-Computer Interface (BCI) System«. V: *IEEE transactions on bio-medical engineering* 51.6 (jun. 2004), str. 1034–1043. ISSN: 0018-9294. DOI: 10.1109/TBME.2004.827072. pmid: 15188875.
- [3] Anil Seth. »Granger Causality«. V: *Scholarpedia* 2.7 (6. jul. 2007), str. 1667. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.1667. URL: [http://www.scholarpedia.org/article/Granger\\_causality](http://www.scholarpedia.org/article/Granger_causality) (pridobljeno 16.6.2024).
- [4] Olaf Sporns. »Brain Connectivity«. V: *Scholarpedia* 2.10 (28. okt. 2007), str. 4695. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.4695. URL: [http://www.scholarpedia.org/article/Brain\\_connectivity](http://www.scholarpedia.org/article/Brain_connectivity) (pridobljeno 16.6.2024).
- [5] Gerwin Schalk in sod. *EEG Motor Movement/Imagery Dataset*. physionet.org, 2009. DOI: 10.13026/C28G6P. URL: <https://physionet.org/content/eegmimdb/> (pridobljeno 13.6.2024).
- [6] Mike X Cohen. *Analyzing Neural Time Series Data: Theory and Practice*. The MIT Press, 17. jan. 2014. ISBN: 978-0-262-31955-3. DOI: 10.7551/mitpress/9609.001.0001.
- [7] Michael Nunez, Paul Nunez in Ramesh Srinivasan. »Electroencephalography (EEG): Neurophysics, Experimental Methods, and Signal Processing«. V: 1. jan. 2016, str. 175–197. ISBN: 978-1-4822-2097-1. DOI: 10.13140/RG.2.2.12706.63687.
- [8] Zoran Šverko in sod. »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis«. V: *Sensors (Basel, Switzerland)* 22.4 (14. feb. 2022), str. 1477. ISSN: 1424-8220. DOI: 10.3390/s22041477. pmid: 35214379. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8879969/> (pridobljeno 17.6.2024).



- [9] *Cognionics QUICK-20 User Manual (Page 28 of 41) | ManualsLib*. URL: <https://www.manualslib.com/manual/2823961/Cognionics-Quick-20.html?page=28#manual> (pridobljeno 9. 7. 2024).
- [10] *Dry EEG Headset | Quick-20r*. CGX. URL: <https://www.cgxsystems.com/quick-20r-v2> (pridobljeno 20. 6. 2024).
- [11] *EEGLAB*. URL: <https://sccn.ucsd.edu/eeglab/index.php> (pridobljeno 13. 6. 2024).
- [12] *Electrode Arrangement According to the International 10/20 System*. URL: <https://www.ternimed.de/EEG-Electrode-arrangement-according-to-the-international-10/20-system> (pridobljeno 20. 6. 2024).
- [13] [https://www.physionet.org/content/eegmmidb/1.0.0/64\\_channel\\_sharbrough.pdf](https://www.physionet.org/content/eegmmidb/1.0.0/64_channel_sharbrough.pdf). URL: [https://www.physionet.org/content/eegmmidb/1.0.0/64\\_channel\\_sharbrough.pdf](https://www.physionet.org/content/eegmmidb/1.0.0/64_channel_sharbrough.pdf) (pridobljeno 26. 6. 2024).
- [14] *Lsl-Website*. URL: <https://labstreaminglayer.org/#/> (pridobljeno 13. 6. 2024).
- [15] *MATLAB*. URL: <https://www.mathworks.com/products/matlab.html> (pridobljeno 2. 7. 2024).