

UNIVERZA NA PRIMORSKEM  
FAKULTETA ZA MATEMATIKO, NARAVOSLOVJE IN  
INFORMACIJSKE TEHNOLOGIJE

Zaključna naloga

**Razpoznavanje gibanja na osnovi elektroencefalografije**

(Movement recognition based on electroencephalography)

Ime in priimek: Marko Rozman

Študijski program: Računalništvo in informatika

Mentor: doc. dr. Peter Rogelj

**Koper, Julij 2024**

## Ključna dokumentacijska informacija

Ime in PRIIMEK:

Naslov zaključne naloge:

Kraj:

Leto:

Število listov:

Število slik:

Število tabel:

Število prilog:

Število strani prilog:

Število referenc:

Mentor:

Somentor:

Ključne besede:

Math. Subj. Class. (2010):

### Izvleček:

Izvleček predstavlja kratek, a jedrnat prikaz vsebine naloge. V največ 250 besedah nakažemo problem, metode, rezultate, ključne ugotovitve in njihov pomen.

## Key words documentation

Name and SURNAME:

Title of final project paper:

Place:

Year:

Number of pages:

Number of figures:

Number of tables:

Number of appendices:

Number of appendix pages:

Number of references:

Mentor: title First Name Last Name, PhD

Co-Mentor:

Keywords:

Math. Subj. Class. (2010):

**Abstract:**

## Zahvala

Tu se zahvalimo sodelujočim pri zaključni nalogi, osebam ali ustanovam, ki so nam pri delu pomagale ali so delo omogočile. Zahvalimo se lahko tudi mentorju in morebitnemu somentorju.

# Kazalo vsebine

<b>1</b>	<b>Uvod</b>	<b>1</b>
1.1	Elektroencefalografija . . . . .	2
1.1.1	Mednarodni sistem 10-20 pozicioniranja elektrod . . . . .	3
1.1.2	Cognionics Quick-20 . . . . .	4
1.2	Povezljivost . . . . .	4
<b>2</b>	<b>Metode</b>	<b>6</b>
2.1	Razvojno okolje MATLAB . . . . .	6
2.1.1	EEGLAB . . . . .	7
2.1.2	Lab streaming layer . . . . .	7
2.1.3	Classification learner . . . . .	8
2.2	EEG Motor Movement/Imagery Dataset . . . . .	8
2.3	Metode povezljivosti . . . . .	9
2.3.1	Grangerjev index vzročnosti . . . . .	9
2.3.2	Kompleksni Pearsonov korelacijski koeficient . . . . .	11
2.4	Klasifikacija . . . . .	11
2.4.1	Classification learner . . . . .	11
2.4.2	Arhitektura nevronska mreža . . . . .	11
<b>3</b>	<b>Rezultati</b>	<b>13</b>
3.1	Delitev podatkov . . . . .	13
3.2	Izbira metode povezljivosti . . . . .	13
3.2.1	Primerjava filtrov . . . . .	15
3.3	Rezultati na MMID . . . . .	18
3.3.1	Classification learner . . . . .	18
3.3.2	Nevronska mreža . . . . .	20
3.4	Rezultati na lastnih podatkih . . . . .	20
3.5	Preizkus v realnem času . . . . .	21
<b>4</b>	<b>Zaključki</b>	<b>22</b>

# Kazalo tabel

1	Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podtakov MMID. . . . .	9
2	Točnost vseh testiranih klasifikacijskih metod v aplikaciji Clasification Learner. . . . .	19

# Kazalo slik

1	Prvih 8 sekund EEG signala elektrode C3, osebe S001 serije R03. Od zgoraj navzdol po področjih: vsa skupaj, delta, theta, alpha, beta, gamma.	2
2	Prikaz pozicije elektrod po mednarodnem sistemu 10-20. Nameščene v mrežo od naziona do iniona in od levevega do desnega sluhovoda v presledkih 10 in 20 odstotkov. [11]	3
3	EEG naprava Cognionics Quick-20. [9]	4
4	Programsko okolje MATLAB. Od leve proti desni: podokno z datotekami, podokno s kodo, podokno s spremenljivkami. Zgoraj zavijki za orodjarno, aplikacije in prikaz podatkov.	6
5	Orodjarna eeglab. Zgoraj zavijki za delo z datotekami, urejanje, orodja, prikaz podatkov, delo z zbirkami podatkov in pomoč. Naložen podatkovni niz dolžine 124 sekund z 30 dogodki.	7
6	Aplikacija classification learner. Na levi strani podokno z različnimi metodami klasifikacije, na sredini prikaz podrobnosti izbrane metode. Zgoraj zavijki za učenje, testiranje in razlago.	8
7	Postavitev elektrod po mednarodnem sistemu 10-10 brez elektrod Nz, F9, F10, FT9, FT10, A1, A2, TP9, TP10, P9, in P10, ki je bila uporabljena za snemanje zbirke MMID. [12]	10
8	Arhitektura nevronske mreže v MATLAB aplikaciji Deep Network Designer. Od zgoraj navzdol: plast za slike, polno povezana, Leaky ReLU, dropout, polno povezana, GELU, dropout, polno povezana in Softmax.	12
9	Primerjava točnosti po območjih in epohah za CPCC in GC. Od zgoraj navzdol CPCC po pasovih delta, theta, alpha, beta in gamma. Spodnja vrstica Grangerjev index vzorčnosti. Epohe od leve proti desni: prva sekunda, prvi dve sekundi, drugi dve sekundi, prve štiri sekunde.	14
10	Primerjava točnosti klasifikacije glede na tip filtra. Uporabljena metoda CPCC za epoho prvih štirih sekund za frekvenčne pasove delta, theta, alpha, beta in gamma. Klasificirano z zgoraj navedeno nevronske mrežo. Modra predstavlja Butterwothov filter, oranžna predstavlja filter z ničelno fazo.	15

11	Matrika zmede nevronske mreže naučene na podatkih fitriranih s filtrom z ničelno fazo. Uporabljena metoda CPCC za epoho prvih štirih sekund za frekvenčni pas beta. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: skrčena desna pest, skrečena leva pest, stanje mirovanja. . . . .	16
12	Matrika zmede nevronske mreže naučene na podatkih fitriranih z Butterworthovim filtrom. Uporabljena metoda CPCC za epoho prvih štirih sekund za frekvenčni pas beta. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: skrčena desna pest, skrečena leva pest, stanje mirovanja. . . . .	17
13	Matrika zmede metode Quadratic SVM. V poljih vidno število klasificiranih stanj. Od zgoraj navzdol: skrčena desna pest, skrčena leva pest, stanje mirovanja. . . . .	18
14	Matrika zmede nevronske mreže. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: skrčena desna pest, skrčena leva pest, stanje mirovanja. . . . .	20
15	Matrika zmede nevronskih mrež dodatno naučenih na naših podatkih. .	21



# Kazalo prilog

# Seznam kratic

*tj.* to je

*npr.* na primer


PLI phase lag Index

# 1 Uvod

Motivacija za raziskavo je bilo ugotoviti do kakšne mere je mogoča razpoznavanje gibanja v živo na osnovi analize možganske aktivnosti z EEG meritvami. Najprej smo podatke iz prosto dostopne zbirke podatkov s pomočjo knjižnice EEGLAB razdelili na nekaj različno dolgih epoh po dogodkih in jim zožili frekvenčne pasove. Iz vsake pridobljene zbirke podatkov smo pridobili matrike povezljivosti Grangerjevega indexa vzročnosti in matrike povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta. Na pridobljenih podatkih smo naučili nevronske mreže. Iz pridobljenih rezultatov smo se odločili za nadaljevanje razvoja na zbirki, ki je obetala najboljšo točnost. Da bi omogočili delovanje v realnem času smo sami implementirali nekaj že obstoječih funkcij iz knjižnice. Posneli smo podatke na Cognionics Quick-20 in dodatno naučili nevronske mreže na naših podatkih za boljšo klasifikacijo.

## 1.1 Elektroencefalografija


Elektroencefalografija (EEG) je metoda za merjenje možganske električne aktivnosti. Meri električne potenciale na površini temena ki jih deloma generira možganska aktivnost. V zadnjem stoletju so znanstveniki s pomočjo EEG pridobili vpogled v različne nevrološke bolezni. V zadnjem času pa se pojavlja interes v modeliranju eeg signalov in uporabo le teh za nadzor fizičnih naprav. EEG signali so običajno razdeljeni v območja ki odražajo različne spektralne vrhove. Ta območja so običajno določena kot delta (1-4 Hz), theta (4-8 Hz), alpha (8-13 Hz), beta (13-20 Hz), in gamma (<20 Hz). [7]



Slika 1: Prvih 8 sekund EEG signala elektrode C3, osebe S001 serije R03. Od zgoraj navzdol po področjih: vsa skupaj, delta, theta, alpha, beta, gamma.

### 1.1.1 Mednarodni sistem 10-20 pozicioniranja elektrod

Mednarodni sistem 10-20 standardizira mesta elektrod tako, da so te nameščene v mrežo od naziona do iniona ter od desnega do levega sluhovoda v presledkih 10 in 20 odstotkov razdalje. Vsaka elektroda je označena z črko lokacijo: T-Temporal, F-Frontal, P-Parietal, C-Central in O-Occipital, ter z črko z za elektrode na sredini glave, lihimi številkami za levo polovico glave in sodimi za desno. [1]



Slika 2: Prikaz pozicije elektrod po mednarodnem sistemu 10-20. Nameščene v mrežo od naziona do iniona in od levevega do desnega sluhovoda v presledkih 10 in 20 odstotkov. [11]

### 1.1.2 Cognionics Quick-20

Cognionics Quick-20 je brezžična suha EEG naprava za raziskovalne namene. Ima 21 elektrod postavljenih po mednarodnem sistemu 10-20 za pozicioniranje elektrod. Naprava je suhega tipa kar pomeni, da pri uporabi elektrode ne potrebujejo gela. Suhi tipi naprav so v primerjavi z mokrimi enostavni in udobni za uporabo in omogočajo hitro nastavitve. Naprava je brezžična, z računalnikom jo povežemo preko USB vmesnika. [9]



Slika 3: EEG naprava Cognionics Quick-20. [9]

## 1.2 Povezljivost


Povezljivost se nananaša na vzorce nastale zaradi anatomskih povezav možganov, statistične odvisnosti ali interakcij med posameznimi deli možganov. Enote med katerimi se meri povezljivost so lahko različne: posamezni nevroni, nevronske populacije, v našem primeru pa regije možganske skorje. Možganska aktivnost je omejena s povezljivostjo, le ta pa je zato ključnega pomena za razumevanje delovanja možganov. V grobem poznamo dve vrsti povezljivosti: strukturno in funkcijsko. Strukturna povezanost se nanaša na to kako so deli možganov med seboj fizično povezani. Funkcijska povezljivost pa se nanaša na to kako različni deli možganov med seboj komunicirajo oziroma sodelujejo. [4] Funkcijsko povezljivost lahko nadaljno delimo na usmerjeno in neusmerjeno. V našem primeru je metoda Grangerjevega indexa vzročnosti usmerjena saj je vpliv elektrode  $A$  na elektrodo  $B$  drugačen kot vpliv elektrode  $B$  na elektrodo  $A$ . Metoda kompleksnega Pearsonovega korelacijskega koeficienta pa je neusmerjena saj nam

njegova vrednost pove le o povezanosti para elektrod.

## 2 Metode

### 2.1 Razvojno okolje MATLAB

Ves razvoj je potekal v programskem okolju MATLAB. Ta poleg samega programskega jezika vsebuje velik nabor že implementiranih funkcij, napredne aplikacije za strojno učenje in knjižnice ki omogočajo povezave z laboratorijskimi napravami. V njem sta ustvarjeni funkciji za računanje matrik Grangerjevega indexa vzročnosti in matrik Kompleksnega Pearsonov korelacijskega koeficienta, prav tako so v njem ustvarjene nevronske mreže in uporabljeno je za ostale klasifikatorje in funkcijo za zajemanje podatkov iz naprave Cognionics Quick-20 ter funkcijo ki v realnem času razpoznava gibanje. [14]




Slika 4: Programsko okolje MATLAB. Od leve proti desni: podokno z datotekami, podokno s kodo, podokno s spremenljivkami. Zgoraj zavihki za orodjarno, aplikacije in prikaz podatkov.



### 2.1.1 EEGLAB

EEGLAB je interaktivna matlab orodjarna, za procesiranje in obdelavo elektrofizioloških podatkov. Omogoča rereferenciranje EEG signalov, izbiro določenih elektrod, deljenje podatkov na epohe glede na dogodke in filtriranje frekvenc. Omogoča interakcijo preko uporabniškega vmesnika. Vse akcije v vmesniku se prevedejo v ukaze ki jih lahko uporabimo v svoji kodi. Pri izdelavi naloge smo največ uporabljali funkcije branja .edf datotek, filtriranja frekvenc signalov in deljanja posnetkov na manjše dele.[10]




Slika 5: Orodjarna eeglab. Zgoraj zavihki za delo z datotekami, urejanje, orodja, prikaz podatkov, delo z zbirkami podatkov in pomoč. Naložen podatkovni niz dolžine 124 sekund z 30 dogodki.

### 2.1.2 Lab streaming layer

Lab streaming layer je odprtokodna vmesna programska oprema ki omogoča pošiljanje, prejemanje, sinhronizacijo in snemanje tokov podatkov. Omogoča enostavno povezovanje EEG naprave z programsko opremo MATLAB. Knjižnjico je potrebno prenesti in nato zgraditi na svojem računalniku. [13]

### 2.1.3 Classification learner

Classification learner je aplikacija v okolju MATLAB za enostavno klasifikacijo podatkov. Podpira različne metode klasifikacije, prečno preverjanje in uporabo različnih podatkov za gradnjo in testiranje modela. Aplikacija podpira klasifikacijo podatkov iz dvo dimenzionalnih matrik kjer vrstice ali stolpci predstavljajo spremenljivke. Oznake podatkov lahko podamo kot določeno vrstico ali stolpec matrike ali v ločeni spremenljivki. Zaradi omejitev aplikacije smo pred klasifikacijo matrike povezljivosti prevorili v vektorje in te združili v matriko podatkov. Z aplikacijo smo lahko hitro ocenili uspešnost računanja matrik povezljivosti in primerjali delovanje različnih klasifikatorjev v primerjavi z našo nevronske mrežo.



Slika 6: Aplikacija classification learner. Na levi strani podokno z različnimi metodami klasifikacije, na sredini prikaz podrobnosti izbrane metode. Zgoraj zavijki za učenje, testiranje in razlago.

## 2.2 EEG Motor Movement/Imagery Dataset

EEG Motor Movement/Imagery Dataset(MMID) je prosto dostopna zbirka več kot 1500 eno in dve minutnih posnetkov 109 prostovoljcev. Zbirka za vsakega prostovoljca

vsebuje dva izhodiščna posnetka in po tri posnetke opravljanja štiri različnih nalog: stiskanje in sproščanje leve ali desne pesti(naloga 1), namišljeno stiskanje in sproščanje leve ali desne pesti(naloga 2), stiskanje in sproščanje obeh pesti ali obeh stopal(naloga 3), namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal(naloga 4). Za nas relevantni so posnetki serij 3, 7 in 11 v katerih prostovoljci opravljajo prvo nalogo. Posnetki so shranjeni v formatu EDF+ ki vsebuje posnetke EEG in oznake dogodkov. Snemanje je bilo opravljeno z sistemom BCI2000 z 64 elektrodami postavljenimi po mednarodnem sistemu 10-10 brez elektrod Nz, F9, F10, FT9, FT10, A1, A2, TP9, TP10, P9, in P10.[2, 5]

Številka serije	Naloga	Opis naloge
1	izhodišče	odpte oči
2	izhodišče	zaprte oči
3	naloga 1	stiskanje in sproščanje leve ali desne pesti
4	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
5	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
6	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
7	naloga 1	stiskanje in sproščanje leve ali desne pesti
8	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
9	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
10	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
11	naloga 1	stiskanje in sproščanje leve ali desne pesti
12	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
13	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
14	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal


Tabela 1: Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podatkov MMID.

## 2.3 Metode povezljivosti

### 2.3.1 Grangerjev index vzročnosti

Grangerjev index vzročnosti je statistična metoda za preverjanje ali ena časovna vrsta nosi informacije o drugi. Metoda je bila razvita v šestdesetih letih devetnajstega stoletja za uporabo ekonomiji.[6]

Za dve časovni vrsti  $X_1$  in  $X_2$ , in  $p$  kot število prejšnjih vrednosti ki jih upoštevamo pri računanju, lahko izračunamo  $E_1$  in  $E_2$  ki so napake pri predvidevanju naslednje



Slika 7: Postavitev elektrod po mednarodnem sistemu 10-10 brez elektrod Nz, F9, F10, FT9, FT10, A1, A2, TP9, TP10, P9, in P10, ki je bila uporabljena za snemanje zbirke MMID. [12]

vrednosti v vrsti  $X_1$ . V kolikor je varianca vrednosti  $E_2$  manjša kot varianca vrednosti  $E_1$  lahko predvidevamo da časovna vrsta  $X_2$  nosi informacije o časovni vrsti  $X_1$ .  $A_1$ ,  $A_2$  in  $A_3$  so koeficienti avto-regresivnega modela. [3]

$$X_1(t) = \sum_{j=1}^p A_{1,j} X_1(t-j) + E_1(t)$$

$$X_1(t) = \sum_{j=1}^p A_{2,j} X_1(t-j) + \sum_{j=1}^p A_{3,j} X_2(t-j) + E_2(t)$$

### 2.3.2 Kompleksni Pearsonov korelacijski koeficient

Pearsonov korelacijski koeficient je najpogosteje uporabljen linearni korelacijski koeficient. Zanj smo se odločili saj v članku »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis« avtorji pokažejo da vsebuje informacije PLI in wPLI ki sta dve najbolj pogosto uporabljeni metodi povezljivosti. V praksi nam pove, v kakšni meri sta fazi dveh signalov linearno povezani.[8]

Ker želimo opazovati faze EEG signala, ga potrebujemo pretvoriti v analitični signal ki vsebuje informacijo o fazi. Zaradi sledeče transformacije, ki je definirana samo na ozkih frekvenčnih pasovih potrebujemo signale EEG predhodno filtrirati. Analitični signal  $X_a$  kjer  $HT(X(t))$  označuje hilbertovo transformacijo signala  $X$ . [8]

$$X_a(t) = X(t) + i \cdot HT(X(t))$$

Za računanje Kompleksnega Pearsonovega korelacijskega koeficienta v našem primer lahko uporabimo naslednjo enačbo kjer sta  $X_1$  in  $X_2$  analitična signal dolžine  $N$ .  $\overline{X_2(n)}$  pa konjugirana vrednost  $X_2(n)$ [8]

$$r(X_1, X_2) = \frac{\sum_{n=1}^N (X_1(n) \cdot \overline{X_2(n)})}{\sqrt{\sum_{n=1}^N |X_1(n)|^2} \cdot \sqrt{\sum_{n=1}^N |X_2(n)|^2}}$$

## 2.4 Klasifikacija

Želeli smo preizkusiti kako uspešno bi klasifikacija delovala na podatkih zbirke in kako uspešno bi delovala na naših podatkih, zato smo klasifikacijo izvajali dvakrat. Enkrat na podatkih zbirke in enkrat na naših podatkih. Ker nevronska mreža za učenje potrebuje več podatkov kot jih lahko zagotovimo iz naših posnetkov smo jo za namene klasifikacije naših posnetkov naučili na podatkih MMID in nato dodatno naučili na naših podatkih.


### 2.4.1 Classification learner

Na matrikah povezljivosti pridobljenih iz podatkov zbirke in naših posnetkov smo izvedli več različnih vrst klasifikacije in sicer: odločitvena drevesa, metodo k najbližjih sosedov (k-NN), logistično regresijo, podporne vektorske stroje (SVM), ansabelske metode in nevronske mreže.

### 2.4.2 Arhitektura nevronska mreža

Nevronska mreža je sestavljena iz vhodne plasti za slike dimenzij 19x19x1, polno povezane plasti s 100 nevroni, Leaky ReLU plasti, dropout plasti z 50% verjetnostjo

opustitve nevronov, polno povezane plasti z 10 nevroni, GELU plasti, dropout plasti z 50% verjetnostjo opustitve nevronov, polno povezane plasti s tremi nevroni in Softmax plasti. Mreža je realizirana z pomočjo MATLAB orodjarne Deep Learning Toolbox.



Slika 8: Arhitektura nevronske mreže v MATLAB aplikaciji Deep Network Designer. Od zgoraj navzdol: plast za slike, polno povezana, Leaky ReLU, dropout, polno povezana, GELU, dropout, polno povezana in Softmax.


## 3 Rezultati

### 3.1 Delitev podatkov

Za končno raziskavo smo izbrali posnetke serij 3, 7 in 11 iz MMID. Vsaka serija vsebuje 109 posnetkov, vsak posnetk 30 primerov stanj, vse skupaj smo jih pridobili 9854. Primere stanj smo skrčili na enakomerno razporeditev, z 2456 primeri vsakega stanja. Sami smo posneli neka minut posnetkov. Vse skupaj 250 primerov stanj, ki smo jih skrčili na enakomerno razporeditev, 62 primerov vsakega stanja. Za učenje nevronske mreže smo uporabljali množice za učenje z 75% podatkov in množice za testiranje z 25% podatkov. Podatki so bili naključno razporejeni med učno in testno množico. Ker smo podatke delili naključno, se lahko posnetki stanj enega prostovoljca pojavijo v učni in testni množici. Pri dodatnem učenju mreže smo uporabili posnetke ene osebe za učenje in testiranje. To skupaj pomeni da sistem ne deluje medosebno.


### 3.2 Izbira metode povezljivosti

Ker je kompleksni Pearsonov korelacijski koeficient(CPCC) izračunan iz analitičnih signalov ga lahko definiramo samo za ozke frekvenčne pasove. Pri računanju Grangerjevega indeksa vzročnosti(GC) te omejitve ni, tako da smo ga lahko računali na celotnem frekvenčnem območju do 45Hz. Prav tako se je pojavilo vprašanje koliko dolgo epoho EEG signala bomo potrebovali za uspešno klasifikacijo. Kot možnosti smo vzeli prvo sekundo, prvi dve sekundi, drugi dve sekundi in prve štiri sekunde po dogodku. Točnost klasifikacije smo ocenili z zgoraj navedeno nevronske mrežo. Za najboljšo metodo se je izkazal kompleksni Pearsonov korelacijski koeficient na območju 13-30Hz z najdaljšimi epohami, 4s. Celotno območje primerjav razvidno iz slike 9.



Slika 9: Primerjava točnosti po območij in epohah za CPCC in GC. Od zgoraj navzdol CPCC po pasovih delta, theta, alpha, beta in gamma. Spodnja vrstica Grangerjev index vzorčnosti. Epohe od leve proti desni: prva sekunda, prvi dve sekundi, drugi dve sekundi, prve štiri sekunde.







Slika 10: Primerjava točnosti klasifikacije glede na tip filtra. Uporabljen metoda CPCC za epoko prvih štirih sekund za frekvenčne pasove delta, theta, alpha, beta in gamma. Klasificirano z zgoraj navedeno nevronske mrežo. Modra predstavlja Butterworthov filter, oranžna predstavlja filter z ničelno fazo.

### 3.2.1 Primerjava filtrov

Knjižnica EEGLAB vsebuje samo filtre z ničelno fazo, ki filtrirajo naprej in nato nazaj po času, kar v našem primeru ni primerno saj podatke prejemamo sekvenčno, zato smo podatke filtrirali s pomočjo Butterworthovega filtra ki vsebuje stanja. Stanja nam omogočajo filtriranje sekvenčnih podatkov saj preprečijo napako na začetku filtra kjer le ta potrebuje predpostaviti začetno stajanje vseh signalov 0. Ker filtra nista enakovredna saj prvi ne spreminja faz drugi pa jih zamakne, uporabljena metoda CPCC pa deluje na zamikih faz, smo izvedli dodatno testiranje, da smo preverili če pristop deluje enako učinkovito. Klasifikacija matrik pridobljenih z Butterworthovim filtrom (slika 12) v primerjavi z filtrom z ničelno fazo (slika 11) je bila primerljivo točna za frekvenčni pas beta (slika 10) iz česar lahko sklepamo, da je filtriranje z Butterworthovim filtrom primerno.



Slika 11: Matrika zmede nevronske mreže naučene na podatkih fitriranih s filtrom z ničelno fazo. Uporabljena metoda CPCC za epoho prvih štirih sekund za frekvenčni pas beta. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: skrčena desna pest, skrečena leva pest, stanje mirovanja.



Slika 12: Matrika zmede nevronske mreže naučene na podatkih fitriranih z Butterworthovim filtrom. Uporabljena metoda CPCC za epoho prvih štirih sekund za frekvenčni pas beta. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: skrčena desna pest, skrečena leva pest, stanje mirovanja.

**Model 2.11 (Quadratic SVM)**

True Class	1	1360	560	536
	2	455	1278	723
	3	467	706	1283
		1	2	3
		Predicted Class		

Slika 13: Matrika zmede metode Quadratic SVM. V poljih vidno število klasificiranih stanj. Od zgoraj navzdol: skrčena desna pest, skrčena leva pest, stanje mirovanja.


### 3.3 Rezultati na MMID

#### 3.3.1 Classification learner

Z uporabo aplikacije clasifacation learner smo testirali več načinov klasifikacije. Iz rezultatov predstavljenih v tabeli 2 lahko razberemo, da so se za najbolj uspešne izkazale metode podpornih vektorjev(SVM), vendar so te metode računsko zahtevne kar otežuje izvedbo v realnem času. Dober kandidat bi lahko bila odločitvena drevesa saj so enostavna za treniranje in iterpretacijo, vendar so le ta dosegla 41% točnost. Nevronske mreže ki jih podpira aplikacija so enostavne, vendar pa je njihova interpretacija težja. Ker ne omogočajo klasifikacije matrik izgubimo prostorske povezave med posameznimi elektrodami. **Je to res?** Dosegle so 49% točnost.

vrsta klasifikacije	metoda	točnost [%]
SVM	Quadratic SVM	53
SVM	Linear SVM	53
SVM	Medium Gaussian SVM	53
Ensemble	Subspace Discriminant	53
SVM	Cubic SVM	52
Kernel	SVM Kernel	52
Kernel	Logistic Regression Kernel	52
SVM	Coarse Gaussian SVM	50
Efficient Logistic Regression	Efficient Logistic Regression	49
Neural Network	Wide Neural Network	49
Neural Network	Medium Neural Network	47
Efficient Linear SVM	Efficient Linear SVM	46
Neural Network	Trilayered Neural Network	45
Neural Network	Bilayered Neural Network	45
Naive Bayes	Kernel Naive Bayes	45
Neural Network	Narrow Neural Network	45
Ensemble	Bagged Trees	44
KNN	Coarse KNN	44
Ensemble	Boosted Trees	43
Ensemble	RUSBoosted Trees	42
Tree	Medium Tree	41
Tree	Fine Tree	41
KNN	Cosine KNN	41
Tree	Coarse Tree	41
KNN	Medium KNN	40
KNN	Weighted KNN	40
Ensemble	Subspace KNN	40
KNN	Cubic KNN	40
KNN	Fine KNN	38
SVM	Fine Gaussian SVM	37

Tabela 2: Točnost vseh testiranih klasifikacijskih metod v aplikaciji Clasification Learner.




Slika 14: Matrika zmede nevronske mreže. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: skrčena desna pest, skrčena leva pest, stanje mirovanja.

3.3.2 Nevronska mreža

Nato smo poskusili z zgoraj navedeno nevronsko mrežo, ki klasificira matrike povezlji-vosti. Mreža je dosegla malo višjo točnost kot metode iz aplikacije clasification learner. V primerjavi z najboljšo metodo aplikaije SVM, ki je dosegla 53% točnost, je mreža dosegla 56% točnost. Če primerjamo matriko zmede nevronske mreže z matriko zmede metode SVM (sliki 14 in 13 ), opazimo, da obe metodi bolj natančno razlikujeta stanje mirovanja od obeh stanj gibanja, medtem ko je razlikovanje med stanji gibanja med seboj manj natančno.

3.4 Rezultati na lastnih podatkih

Da bi se približali pogojem v realnem času, smo nevronsko mrežo dodatno naučili na naših podatkih. Zaradi različnih pogojev snemanja in natančnosti naprav na katerih



Slika 15: Matrika zmede nevronske mreže dodatno naučene na naših podatkih.

so podatki snemani je točnost klasifikacije pričakovano padla. Ker nimamo velikega števila posnetkov smo podatke razdelili na pet delov in mrežo natrenirali petkrat. Vsakič smo uporabili en del za testiranje in štiri za učenje. Predstavljeni podatki so seštevek vseh teh testiranj.

### 3.5 Preizkus v realnem času

## 4 Zaključki

V nalogi smo uspešno razpoznali gibanje iz EEG signalov. Uspešno smo razpoznali gibanje iz podatkovne zbirke MMID posnete po mednarodnem sistemu 10-10 in iz podatkov posnetih na napravi Cognionics Quick-20. Posnete signale smo obdelali z različnimi pristopi. Signale smo rereferencirali, filtrirali z filtrom z ničelno fazo in Butterworthovim filtrom na običajna območja zanimanja pri analizi EEG signalov. Nato smo signale razdelili na različno dolge epohe in izbrali najustrežnejše. Obdelane signale smo pretvorili v matrice povezljivosti s pomočjo Grangerjevega indexa vzročnosti in kompleksnega Pearsonovega korelacijskega koeficienta. Pridobljene matrice smo klasificirali z aplikacijo Classification Learner in z nevronske mreže ki smo jo implementirali sami. Dosegli smo zadovoljive natančnosti na podatkih MMID in podatkih posnetih z napravo Cognionics Quick-20. Metode ki smo jih uporabljali omogočajo boljše razumevanje možganskih aktivnosti kot direktna klasifikacija signalov, z uporabo kompleksnega Pearsonovega korelacijskega koeficienta smo demonstrirali da je razpoznavanje gibanja mogoče iz krajših epoh območja beta. Ugotovili smo, da kompleksni Pearsonov korelacijski koeficient zagotavlja boljšo metodo za izračun povezljivosti kot tradicionalno uporabljeni Grangerjev index vzročnosti. Za delo v realnem času smo sami implementirali in ocenili primernost filtrov ki jih knjižnica EEGLAB ne podpira.

Glavne omejitve ki nam onemogočajo natančnejšo klasifikacijo z uporabljenimi metodami so omejena velikost posnetkov in omejena natančnost naprav EEG. Prav tako naloga vsebuje omejitev pri učenju klasifikatorjev, saj sistema nismo preizkusili pri klasifikacijah EEG signalov oseb na čigar signalih klasifikator ni bil učen.

Klasifikacija gibanja iz signalov EEG ima potencialne aplikacije v medicini, zlasti pri razvoju sistemov za nadzor protez in rehabilitacijskih naprav. Metode povezljivosti, uporabljene v nalogi pa nam lahko poglobijo razumevanje možganske aktivnosti med različnimi fizičnimi nalogami.



# Literatura

- [1] G. H. Klem in sod. »The Ten-Twenty Electrode System of the International Federation. The International Federation of Clinical Neurophysiology«. V: *Electroencephalography and Clinical Neurophysiology. Supplement* 52 (1999), str. 3–6. ISSN: 0424-8155. pmid: 10590970.
- [2] Gerwin Schalk in sod. »BCI2000: A General-Purpose Brain-Computer Interface (BCI) System«. V: *IEEE transactions on bio-medical engineering* 51.6 (jun. 2004), str. 1034–1043. ISSN: 0018-9294. DOI: 10.1109/TBME.2004.827072. pmid: 15188875.
- [3] Anil Seth. »Granger Causality«. V: *Scholarpedia* 2.7 (6. jul. 2007), str. 1667. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.1667. URL: [http://www.scholarpedia.org/article/Granger\\_causality](http://www.scholarpedia.org/article/Granger_causality) (pridobljeno 16. 6. 2024).
- [4] Olaf Sporns. »Brain Connectivity«. V: *Scholarpedia* 2.10 (28. okt. 2007), str. 4695. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.4695. URL: [http://www.scholarpedia.org/article/Brain\\_connectivity](http://www.scholarpedia.org/article/Brain_connectivity) (pridobljeno 16. 6. 2024).
- [5] Gerwin Schalk in sod. *EEG Motor Movement/Imagery Dataset*. physionet.org, 2009. DOI: 10.13026/C28G6P. URL: <https://physionet.org/content/eegmmidb/> (pridobljeno 13. 6. 2024).
- [6] Mike X Cohen. *Analyzing Neural Time Series Data: Theory and Practice*. The MIT Press, 17. jan. 2014. ISBN: 978-0-262-31955-3. DOI: 10.7551/mitpress/9609.001.0001.
- [7] Michael Nunez, Paul Nunez in Ramesh Srinivasan. »Electroencephalography (EEG): Neurophysics, Experimental Methods, and Signal Processing«. V: 1. jan. 2016, str. 175–197. ISBN: 978-1-4822-2097-1. DOI: 10.13140/RG.2.2.12706.63687.
- [8] Zoran Šverko in sod. »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis«. V: *Sensors (Basel, Switzerland)* 22.4 (14. feb. 2022), str. 1477. ISSN: 1424-8220. DOI: 10.3390/s22041477. pmid: 35214379. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8879969/> (pridobljeno 17. 6. 2024).

- [9] *Dry EEG Headset / Quick-20r*. CGX. URL: <https://www.cgxsystems.com/quick-20r-v2> (pridobljeno 20. 6. 2024).
- [10] *EEGLAB*. URL: <https://sccn.ucsd.edu/eeglab/index.php> (pridobljeno 13. 6. 2024).
- [11] *Electrode Arrangement According to the International 10/20 System*. URL: <https://www.ternimed.de/EEG-Electrode-arrangement-according-to-the-international-10/20-system> (pridobljeno 20. 6. 2024).
- [12] [https://www.physionet.org/content/eegmmidb/1.0.0/64\\_channel\\_sharbrough.pdf](https://www.physionet.org/content/eegmmidb/1.0.0/64_channel_sharbrough.pdf). URL: [https://www.physionet.org/content/eegmmidb/1.0.0/64\\_channel\\_sharbrough.pdf](https://www.physionet.org/content/eegmmidb/1.0.0/64_channel_sharbrough.pdf) (pridobljeno 26. 6. 2024).
- [13] *Lsl-Website*. URL: <https://labstreaminglayer.org/#/> (pridobljeno 13. 6. 2024).
- [14] *MATLAB*. URL: <https://www.mathworks.com/products/matlab.html> (pridobljeno 2. 7. 2024).