

UNIVERZA NA PRIMORSKEM  
FAKULTETA ZA MATEMATIKO, NARAVOSLOVJE IN  
INFORMACIJSKE TEHNOLOGIJE

Zaključna naloga

**Razpoznavanje gibanja na osnovi elektroencefalografije**

(Movement recognition based on electroencephalography)

Ime in priimek: Marko Rozman

Študijski program: Računalništvo in informatika

Mentor: doc. dr. Peter Rogelj

**Koper, Julij 2024**

## Ključna dokumentacijska informacija

Ime in PRIIMEK:

Naslov zaključne naloge:

Kraj:

Leto:

Število listov:

Število slik:

Število tabel:

Število prilog:

Število strani prilog:

Število referenc:

Mentor:

Somentor:

Ključne besede:

Math. Subj. Class. (2010):

### Izvleček:

Izvleček predstavlja kratek, a jedrnat prikaz vsebine naloge. V največ 250 besedah nakažemo problem, metode, rezultate, ključne ugotovitve in njihov pomen.

## Key words documentation

Name and SURNAME:

Title of final project paper:

Place:

Year:

Number of pages:

Number of figures:

Number of tables:

Number of appendices:

Number of appendix pages:

Number of references:

Mentor: title First Name Last Name, PhD

Co-Mentor:

Keywords:

Math. Subj. Class. (2010):

**Abstract:**

## Zahvala

Tu se zahvalimo sodelujočim pri zaključni nalogi, osebam ali ustanovam, ki so nam pri delu pomagale ali so delo omogočile. Zahvalimo se lahko tudi mentorju in morebitnemu somentorju.

# Kazalo vsebine

<b>1</b>	<b>Uvod</b>	<b>1</b>
1.1	Elektroencefalografija . . . . .	2
1.1.1	Mednarodni sistem 10-20 pozicioniranja elektrod . . . . .	3
1.1.2	Cognionics Quick-20 . . . . .	4
1.2	Povezljivost . . . . .	4
<b>2</b>	<b>Metode</b>	<b>5</b>
2.1	Razvojno okolje MATLAB . . . . .	5
2.1.1	EEGLAB . . . . .	6
2.1.2	Lab streaming layer . . . . .	6
2.1.3	Classification learner . . . . .	7
2.2	EEG Motor Movement/Imagery Dataset . . . . .	7
2.3	Metode povezljivosti . . . . .	8
2.3.1	Grangerjev index vzročnosti . . . . .	8
2.3.2	Kompleksni Pearsonov korelacijski koeficient . . . . .	9
2.4	Klasifikacija . . . . .	9
2.4.1	Classification learner . . . . .	9
2.4.2	Nevronska mreža . . . . .	10
<b>3</b>	<b>Rezultati</b>	<b>11</b>
3.1	Delitev podatkov . . . . .	11
3.2	Izbira metode povezljivosti . . . . .	11
3.3	Primerjava filtrov . . . . .	11
3.4	Rezultati na MMID . . . . .	12
3.4.1	Classification learner . . . . .	12
3.4.2	Nevronska mreža . . . . .	12
3.5	Rezultati na lastnih podatkih . . . . .	13
3.6	Preizkus v realnem času . . . . .	15
<b>4</b>	<b>Zaključki</b>	<b>16</b>

# Kazalo tabel

1	Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podtakov MMID. . . . .	8
2	Točnost klasifikacij . . . . .	14

# Kazalo slik

1	Prvih 8 sekund EEG signala elektrode C3, osebe S001 serije R03. Od zgoraj navzdol po področjih: vsa skupaj, delta, theta, alpha, beta, gamma.	2
2	Prikaz pozicije elektrod po mednarodnem sistemu 10-20. Nameščene v mrežo od naziona do iniona in od levevega do desnega sluhovoda v presledkih 10 in 20 odstotkov.	3
3	EEG naprava Cognionics Quick-20.	4
4	Programsko okolje MATLAB. Od leve proti desni: podokno z datotekami, podokno s kodo, podokno s spremenljivkami. Zgoraj zavihki za orodjarno, aplikacije in prikaz podatkov.	5
5	Orodjarna eeglab. Zgoraj zavihki za delo z datotekami, urejanje, orodja, prikaz podatkov, delo z zbirkami podatkov in pomoč. Naložen podatkovni niz dolžine 124 sekund z 30 dogodki.	6
6	Aplikacija classification learner. Na levi strani podokno z različnimi metodami klasifikacije, na sredini prikaz podrobnosti izbrane metode. Zgoraj zavihki za učenje, testiranje in razlago.	7
7	Nevronska mreža.	10
8	Primerjava območij in dolžin epoh.	12
9	Primerjava klasifikacije CPCC z nevronske mreže za epoho 0-4s za različne frekvenčne pasove <i>val = eeglab – Butterworth</i> testirano za 30 ljudi * 3 serije	12
10	Matrika zmede nevronske mreže naučene na podatkih fitriranih s filtrom z ničelno fazo.	13
11	Matrika zmede nevronske mreže naučene na podatkih fitriranih z Butterworthovim filtrom.	13
12	Matrika zmede nevronske mreže naučene na podatkih zbirke.	14
13	Matrika zmede nevronske mreže dodatno naučene na naših podatkih.	14

# Kazalo prilog



# Seznam kratic

*tj.* to je

*npr.* na primer


PLI phase lag Index

# 1 Uvod

Motivacija za raziskavo je bilo ugotoviti do kakšne mere je mogoča razpoznavanje gibanja v živo na osnovi analize možganske aktivnosti z EEG meritvami. Najprej smo podatke iz prosto dostopne zbirke podatkov s pomočjo knjižnice EEGLAB razdelili na nekaj različno dolgih epoh po dogodkih in jim zožili frekvenčne pasove. Iz vsake pridobljene zbirke podatkov smo pridobili matrike povezljivosti Grangerjevega indexa vzročnosti in matrike povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta. Na pridobljenih podatkih smo naučili nevronske mreže. Iz pridobljenih rezultatov smo se odločili za nadaljevanje razvoja na zbirki, ki je obetala najboljšo točnost. Da bi omogočili delovanje v realnem času smo sami implementirali nekaj že obstoječih funkcij iz knjižnice. Posneli smo podatke na Cognionics Quick-20 in dodatno naučili nevronske mreže na naših podatkih za boljšo klasifikacijo.

## 1.1 Elektroencefalografija


Elektroencefalografija (EEG) je metoda za merjenje možganske električne aktivnosti. Meri električne potenciale na površini temena ki jih deloma generira možganska aktivnost. V zadnjem stoletju so znanstveniki s pomočjo EEG pridobili vpogled v različne nevrološke bolezni. V zadnjem času pa se pojavlja interes v modeliranju eeg signalov in uporabo le teh za nadzor fizičnih naprav. EEG signali so običajno razdeljeni v območja ki odražajo različne spektralne vrhove. Ta območja so običajno določena kot delta (1-4 Hz), theta (4-8 Hz), alpha (8-13 Hz), beta (13-20 Hz), in gamma (<20 Hz). [6]



Slika 1: Prvih 8 sekund EEG signala elektrode C3, osebe S001 serije R03. Od zgoraj navzdol po področjih: vsa skupaj, delta, theta, alpha, beta, gamma.

### 1.1.1 Mednarodni sistem 10-20 pozicioniranja elektrod

Mednarodni sistem 10-20 standardizira mesta elektrod tako, da so te nameščene v mrežo od naziona do iniona ter od desnega do levega sluhovoda v presledkih 10 in 20 odstotkov razdalje. Vsaka elektroda je označena z črko lokacijo: T-Temporal, F-Frontal, P-Parietal, C-Central in O-Occipital, ter z črko z za elektrode na sredini glave, lihimi številkami za levo polovico glave in sodimi za desno. [1]



Slika 2: Prikaz pozicije elektrod po mednarodnem sistemu 10-20. Nameščene v mrežo od naziona do iniona in od levevega do desnega sluhovoda v presledkih 10 in 20 odstotkov.

### 1.1.2 Cognionics Quick-20

Cognionics Quick-20 je brezžična suha EEG naprava za raziskovalne namene. Ima 21 elektrod postavljenih po mednarodnem sistemu 10-20 za pozicioniranje elektrod. Naprava je suhega tipa kar pomeni, da pri uporabi elektrode ne potrebujejo gela. Suhi tipi naprav so v primerjavi z mokrimi enostavni in udobni za uporabo in omogočajo hitro nastavitev. Naprava je brezžična, z računalnikom jo povežemo preko USB vmesnika.



Slika 3: EEG naprava Cognionics Quick-20.

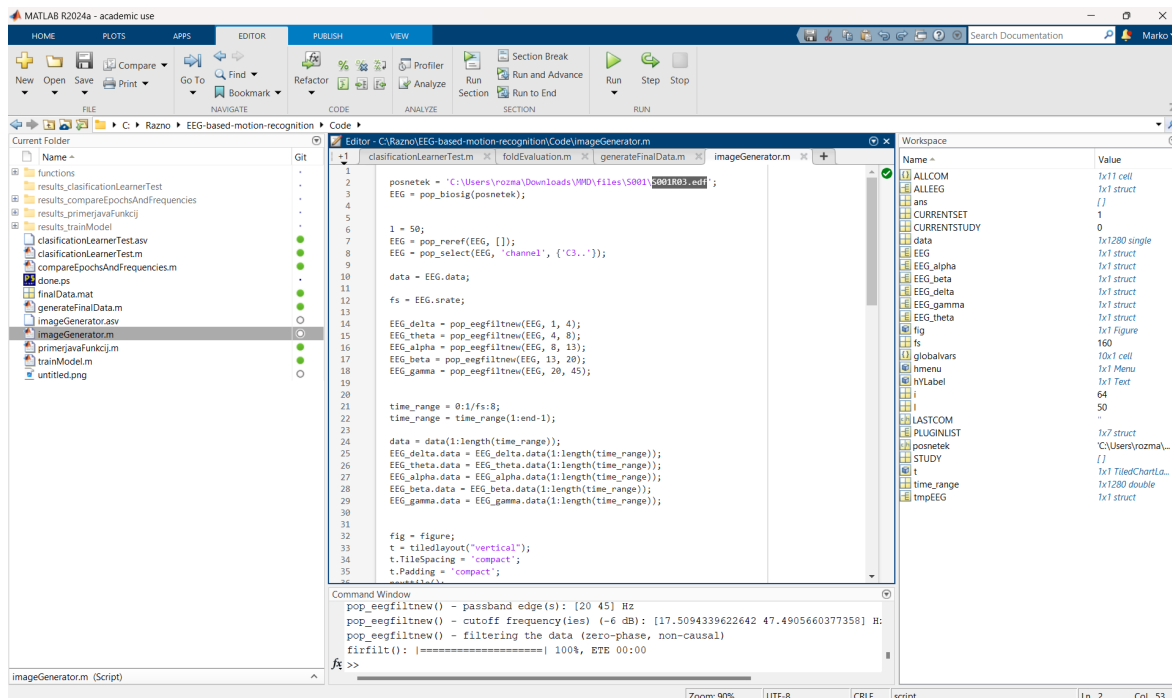
## 1.2 Povezljivost

Povezljivost se nanaša na vzorce nastale zaradi anatomskih povezav možganov, statistične odvisnosti ali interakcij med posameznimi deli možganov. Enote med katerimi se meri povezljivost so lahko različne: posamezni nevroni, nevronske populacije, v našem primeru pa regije možganske skorje. Možganska aktivnost je omejena s povezljivostjo, le ta pa je zato ključnega pomena za razumevanje delovanja možganov. V grobem poznamo dve vrsti povezljivosti: strukturno in funkcijsko. Strukturna povezanost se nanaša na to kako so deli možganov med seboj fizično povezani. Funkcijska povezljivost pa se nanaša na to kako različni deli možganov med seboj komunicirajo oziroma sodelujejo.[4] Funkcijsko povezljivost lahko nadaljno delimo na usmerjeno in neusmerjeno. V našem primeru je metoda Grangerjevega indexa vzročnosti usmerjena saj je vpliv elektrode  $A$  na elektrodo  $B$  drugačen kot vpliv elektrode  $B$  na elektrodo  $A$ . Metoda kompleksnega Pearsonovega korelacijskega koeficienta pa je neusmerjena saj nam pove le o povezanosti para elektrod.

## 2 Metode

### 2.1 Razvojno okolje MATLAB


Ves razvoj je potekal v programskem okolju MATLAB. Ta poleg samega programskega jezika vsebuje velik nabor že implementiranih funkcij, napredne aplikacije za strojno učenje in knjižnice ki omogočajo povezave z laboratorijskimi napravami. V njem sta ustvarjeni funkciji za računanje matrik Grangerjevega indexa vzročnosti in matrik Kompleksnega Pearsonov korelacijskega koeficienta, prav tako so v njem ustvarjene nevronske mreže in uporabljeno je za ostale klasifikatorje in funkcijo za zajemanje podatkov iz naprave Cognionics Quick-20 ter funkcijo ki v realnem času razpoznava gibanje.



Slika 4: Programsko okolje MATLAB. Od leve proti desni: podokno z datotekami, podokno s kodo, podokno s spremenljivkami. Zgoraj zavihki za orodjarno, aplikacije in prikaz podatkov.

### 2.1.1 EEGLAB

EEGLAB je interaktivna matlab orodjarna, za procesiranje in obdelavo elektrofizioloških podatkov. Omogoča rereferenciranje EEG signalov, izbiro določenih elektrod, deljenje podatkov na epohe glede na dogodke in filtriranje frekvenc. Omogoča interakcijo preko uporabniškega vmesnika. Vse akcije v vmesniku se prevedejo v ukaze ki jih lahko uporabimo v svoji kodi. Pri izdelavi naloge smo največ uporabljali funkcije branja .edf datotek, filtriranja frekvenc signalov in deljanja posnetkov na manjše dele.[8]



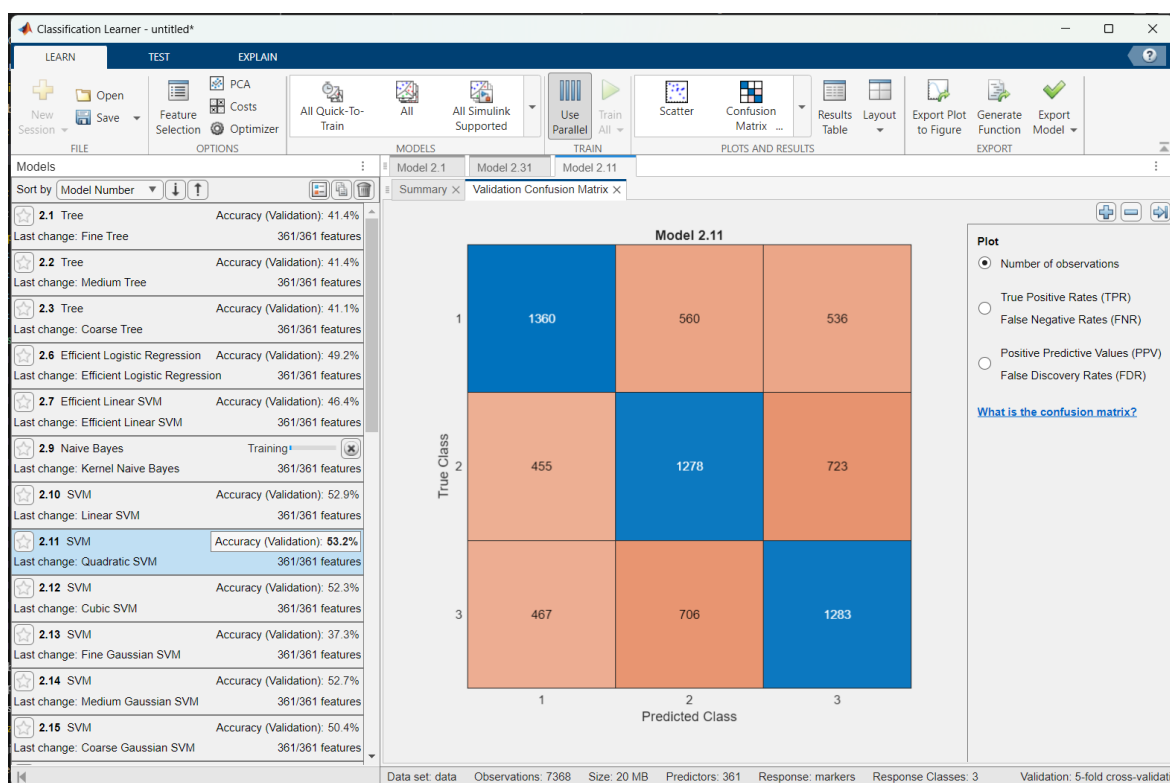
Slika 5: Orodjarna eeglab. Zgoraj zavihki za delo z datotekami, urejanje, orodja, prikaz podatkov, delo z zbirkami podatkov in pomoč. Naložen podatkovni niz dolžine 124 sekund z 30 dogodki.

### 2.1.2 Lab streaming layer

Lab streaming layer je odprtokodna vmesna programska oprema ki omogoča pošiljanje, prejemanje, sinhronizacijo in snemanje tokov podatkov. Omogoča enostavno povezovanje EEG naprave z programsko opremo MATLAB. Knjižnjico je potrebno prenesti in nato zgraditi na svojem računalniku. [9]

### 2.1.3 Classification learner

Classification learner je aplikacija v okolju MATLAB za enostavno klasifikacijo podatkov. Podpira različne metode klasifikacije, prečno preverjanje in uporabo različnih podatkov za gradnjo in testiranje modela. Z njo smo lahko hitro ocenili uspešnost računanja matrik povezljivosti in primerjali delovanje različnih klasifikatorjev v primerjavi z našo nevronske mrežo.



Slika 6: Aplikacija classification learner. Na levi strani podokno z različnimi metodami klasifikacije, na sredini prikaz podrobnosti izbrane metode. Zgoraj zavihki za učenje, testiranje in razlago.

## 2.2 EEG Motor Movement/Imagery Dataset

EEG Motor Movement/Imagery Dataset(MMID) je prosto dostopna zbirka več kot 1500 eno in dve minutnih posnetkov 109 prostovoljcev. Zbirka za vsakega prostovoljca vsebuje dva izhodiščna posnetka in po tri posnetke opravljanja štiri različnih nalog: stiskanje in sproščanje leve ali desne pesti(naloga 1), namišljeno stiskanje in sproščanje leve ali desne pesti(naloga 2), stiskanje in sproščanje obeh pesti ali obeh stopal(naloga 3), namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal(naloga 4). Za nas



relevantni so posnetki serij 3, 7 in 11 v katerih prostovoljci opravljajo prvo nalogo. Posnetki so shranjeni v formatu EDF+ ki vsebuje posnetke EEG in oznake dogodkov. Snemanje je bilo opravljeno s frekvenco 160Hz in 64 elektrodnim sistemom EEG.[5, 2]

Številka serije	Naloga	Opis naloge
1	izhodišče	odpte oči
2	izhodišče	zaprte oči
3	naloga 1	stiskanje in sproščanje leve ali desne pesti
4	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
5	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
6	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
7	naloga 1	stiskanje in sproščanje leve ali desne pesti
8	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
9	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
10	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
11	naloga 1	stiskanje in sproščanje leve ali desne pesti
12	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
13	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
14	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal

Tabela 1: Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podatkov MMID.

## 2.3 Metode povezljivosti

### 2.3.1 Grangerjev index vzročnosti

Grangerjev index vzročnosti je statistična metoda za preverjanje ali ena časovna vrsta nosi informacije o drugi. Metoda je bila razvita v šestdesetih letih devetnajstega stoletja za uporabo ekonomiji.

Za dve časovni vrsti  $X_1$  in  $X_2$ , in  $p$  kot število prejšnjih vrednosti ki jih upoštevamo pri računanju, lahko izračunamo  $E_1$  in  $E_2$  ki so napake pri predvidevanju naslednje vrednosti v vrsti  $X_1$ . V kolikor je varianca vrednosti  $E_2$  manjša kot varianca vrednosti  $E_1$  lahko predvidevamo da časovna vrsta  $X_2$  nosi informacije o časovni vrsti  $X_1$

$$X_1(t) = \sum_{j=1}^p A_{1,j} X_1(t-j) + E_1(t)$$

$$X_1(t) = \sum_{j=1}^p A_{2,j} X_1(t-j) + \sum_{j=1}^p A_{3,j} X_2(t-j) + E_2(t)$$

Mogoče razlaga kaj so A-ji. Ali je pravilno razloženo?

[3]

### 2.3.2 Kompleksni Pearsonov korelacijski koeficient

Pearsonov korelacijski koeficient je najpogostejše uporabljen linearni korelacijski koeficient. Zanj smo se odločili saj v članku »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis« avtorji pokažejo da vsebuje informacije PLI in wPLI ki sta dve najbolj pogosto uporabljeni metodi povezljivosti. V praksi nam pove, v kakšni meri sta fazi dveh signalov linearno povezani.

Ker želimo opazovati faze EEG signala, ga potrebujemo pretvoriti v analitični signal ki vsebuje informacijo o fazi. Zaradi sledeče transformacije, ki je definirana samo na ozkih frekvenčnih pasovih potrebujemo signale EEG predhodno filtrirati. Analitični signal  $X_a$  kjer  $HT(X(t))$  označuje hilbertovo transformacijo signala  $X$ .

$$X_a(t) = X(t) + i \cdot HT(X(t))$$

Za računanje Kompleksnega Pearsonovega korelacijskega koeficienta v našem primer lahko uporabimo naslednjo enačbo kjer sta  $X_1$  in  $X_2$  analitična signal dolžine  $N$ .  $\overline{X_2(n)}$  pa konjugirana vrednost  $X_2(n)$

$$r(X_1, X_2) = \frac{\sum_{n=1}^N (X_1(n) \cdot \overline{X_2(n)})}{\sqrt{\sum_{n=1}^N |X_1(n)|^2} \cdot \sqrt{\sum_{n=1}^N |X_2(n)|^2}}$$

[7]

## 2.4 Klasifikacija


Želeli smo preizkusiti kako uspešno bi klasifikacija delovala na podatkih zbirke in kako uspešno bi delovala na naših podatkih, zato smo klasifikacijo izvajali dvakrat. Enkrat na podatkih zbirke in enkrat na naših podatkih. Ker nevronska mreža za učenje potrebuje več podatkov kot jih lahko zagotovimo iz naših posnetkov smo jo za namene klasifikacije naših posnetkov naučili na podatkih MMID in nato dodatno naučili na naših podatkih.

### 2.4.1 Classification learner

Na matrikah povezljivosti pridobljenih iz podatkov zbirke in naših posnetkov smo izvedli več različnih klasifikacije in sicer: odločitvena drevesa, metodo k najbližjih sosedov (k-NN), logistično regresijo, podporne vektorske stroje (SVM) in nevronske mreže.

## 2.4.2 Nevronska mreža

Nevronska mreža je sestavljena iz vhodne plasti za slike dimenzij 19x19x1, polno povezanega sloja s 100 nevroni, Leaky ReLU sloja, dropout sloja z 50% verjetnostjo opustitve nevronov, polno povezanega sloja z 10 nevroni, GELU sloja, dropout sloja z 50% verjetnostjo opustitve nevronov, polno povezanega sloja s tremi nevroni in Softmax sloja.



Slika 7: Nevronska mreža.

## 3 Rezultati

### 3.1 Delitev podatkov

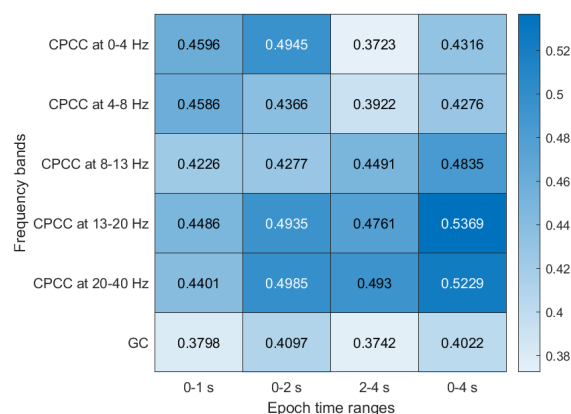
Za končno raziskavo smo imeli na voljo 7368 primerov stanj iz podatkovne zbirke EEG Motor Movement/Imagery Dataset. Primere stanj smo skrčili na enakomerno razporeditev, z 2456 primeri vsakega stanja. Sami smo posneli neka minut posnetkov, 186 primerov stanj od tega 62 primerov vsakega stanja. Za učenje nevronske mreže smo uporabljali množice za učenje z 75% podatkov in množice za testiranje z 25% podatkov.

### 3.2 Izbira metode povezljivosti

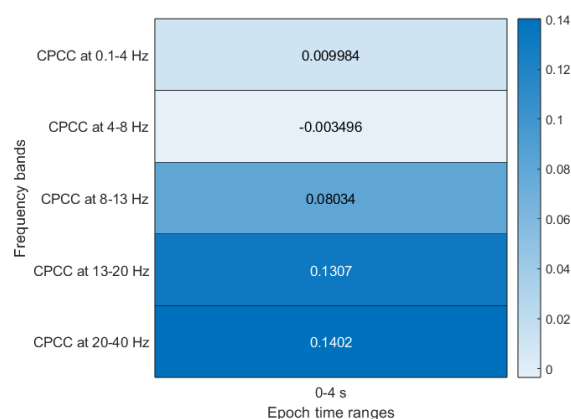
Ker je kompleksni Pearsonov korelacijski koeficient izračunan iz analitičnih signalov ga lahko definiramo samo za ozke frekvenčne pasove. Pri računanju Grangerjevega indeksa vzročnosti te omejitve ni, tako da smo ga lahko računali na celotnem frekvenčnem območju do 45Hz. Prav tako se je pojavilo vprašanje koliko dolgo epoho EEG signala bomo potrebovali za uspešno klasifikacijo. Kot možnosti smo vzeli prvo sekundo, prvi dve sekundi, drugi dve sekundi in prve štiri sekunde po dogodku. Točnost klasifikacije smo ocenili z zgoraj navedeno nevronske mreže. Za najboljšo metodo se je izkazal kompleksni Pearsonov korelacijski koeficient na območju 13-30Hz z najdaljšimi epohami, 4s.

### 3.3 Primerjava filtrov

Knjižnica EEGLAB vsebuje samo filtre z ničelno fazo, ki filtrirajo naprej in nato nazaj po času, kar v našem primeru ni primerno saj podatke prejemamo sekvenčno, zato smo podatke filtrirali s pomočjo Butterworthovega filtra ki vsebuje stanja. Stanja nam omogočajo filtriranje sekvenčnih podatkov saj preprečijo napako na začetku filtra kjer le ta potrebuje predpostaviti začetno stajanje vseh signalov 0. Ker filtra nista enakovredna saj prvi ne spreminja faz drugi pa jih zamakne, uporabljena metoda CPCC pa deluje na zamikih faz, smo izvedli dodatno testiranje, da smo preverili če pristop deluje enako učinkovito.



Slika 8: Primerjava območij in dolžin epoh.

Slika 9: Primerjava klasifikacije CPCC z nevronske mreže za epoho 0-4s za različne frekvenčne pasove *val = eeglab – Butterworth* testirano za 30 ljudi \* 3 serije


## 3.4 Rezultati na MMID

### 3.4.1 Classification learner


Z uporabo aplikacije clasifacation learner smo testirali več načinov klasifikacije in dosegli 49% točnost.

### 3.4.2 Nevronska mreža

Nato smo poskusili z nevronske mreže ki je dosegla 52% točnost.



Slika 10: Matrika zmede nevronske mreže naučene na podatkih fitriranih s filtrom z ničelno fazo.




Slika 11: Matrika zmede nevronske mreže naučene na podatkih fitriranih z Butterworthovim filtrom.

### 3.5 Rezultati na lastnih podatkih


Da bi se približali pogojem v realnem času, smo nevronske mrežo dodatno naučili na naših podatkih. Zaradi različnih pogojev snemanja in dnčnosti naprav na katerih so podatki snemani je točnost klasifikacije pričakovano padla.

Metoda klasifikacije	točnost
odločitvena drevo	40%
k-NN	41%
logistična regresija	49%
SVM	45%

Tabela 2: Točnost klasifikacij



Slika 12: Matrika zmede nevronske mreže naučene na podatkih zbirke.



Slika 13: Matrika zmede nevronske mreže dodatno naučene na naših podatkih.

## 3.6 Preizkus v realnem času



## 4 Zaključki

# Literatura

- [1] G. H. Klem in sod. »The ten-twenty electrode system of the International Federation. The International Federation of Clinical Neurophysiology«. V: *Electroencephalogr Clin Neurophysiol Suppl* 52 (1999), str. 3–6. ISSN: 0424-8155.
- [2] Gerwin Schalk in sod. »BCI2000: a general-purpose brain-computer interface (BCI) system«. V: *IEEE Trans Biomed Eng* 51.6 (jun. 2004), str. 1034–1043. ISSN: 0018-9294. DOI: 10.1109/TBME.2004.827072.
- [3] Anil Seth. »Granger causality«. V: *Scholarpedia* 2.7 (6. jul. 2007), str. 1667. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.1667. URL: [http://www.scholarpedia.org/article/Granger\\_causality](http://www.scholarpedia.org/article/Granger_causality) (pridobljeno 16. 6. 2024).
- [4] Olaf Sporns. »Brain connectivity«. V: *Scholarpedia* 2.10 (28. okt. 2007), str. 4695. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.4695. URL: [http://www.scholarpedia.org/article/Brain\\_connectivity](http://www.scholarpedia.org/article/Brain_connectivity) (pridobljeno 16. 6. 2024).
- [5] Gerwin Schalk in sod. *EEG Motor Movement/Imagery Dataset*. 2009. DOI: 10.13026/C28G6P. URL: <https://physionet.org/content/eegmmidb/> (pridobljeno 13. 6. 2024).
- [6] Michael Nunez, Paul Nunez in Ramesh Srinivasan. »Electroencephalography (EEG): neurophysics, experimental methods, and signal processing«. V: 1. jan. 2016, str. 175–197. ISBN: 978-1-4822-2097-1. DOI: 10.13140/RG.2.2.12706.63687.
- [7] Zoran Šverko in sod. »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis«. V: *Sensors (Basel)* 22.4 (14. feb. 2022), str. 1477. ISSN: 1424-8220. DOI: 10.3390/s22041477. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8879969/> (pridobljeno 17. 6. 2024).
- [8] *EEGLAB*. URL: <https://sccn.ucsd.edu/eeglab/index.php> (pridobljeno 13. 6. 2024).
- [9] *lsl-website*. URL: <https://labstreaminglayer.org/#/> (pridobljeno 13. 6. 2024).