

UNIVERZA NA PRIMORSKEM
FAKULTETA ZA MATEMATIKO, NARAVOSLOVJE IN
INFORMACIJSKE TEHNOLOGIJE

Zaključna naloga

Razpoznavanje gibanja na osnovi elektroencefalografije

(Movement recognition based on electroencephalography)

Ime in priimek: Marko Rozman

Študijski program: Računalništvo in informatika

Mentor: doc. dr. Peter Rogelj

Koper, Julij 2024

Ključna dokumentacijska informacija

Ime in PRIIMEK: Marko ROZMAN

Naslov zaključne naloge: Razpoznavanje gibanja na osnovi elektroencefalografije

Kraj: Koper

Leto: 2024

Število listov: 33

Število slik: 15

Število tabel: 2

Število referenc: 15

Mentor: doc. dr. Peter Rogelj

Ključne besede: elektroencefalografija, Grangerjev indeks vzročnosti, kompleksni Pearsonov korelacijski koeficient, nevronska mreža, razvrščanje

Izvleček:

Namen naloge je preveriti zmožnost razpoznavanja gibanja na osnovi ocenjene možganske povezljivosti temelječe na podatkih elektroencefalografije. Gibanje smo razpoznali iz podatkov EEG Motor Movement/Imagery Dataset in podatkov ki smo jih posneli sami na napravi Cognionics Quick-20. Iz posnetkov smo izračunali matrike povezljivosti z Grangerjevim indeksom vzročnosti in kompleksnim Pearsonovim korelacijskim koeficientom ki smo jih nato razvrstili z različnimi algoritmi, vključno z nevronskimi mrežami. Naši rezultati pokažejo, da je gibanje mogoče razvrstiti z značilkami, ki izhajajo iz možganske povezljivosti. Ob uporabi optimalnega frekvenčnega pasu, ki je v našem primeru 13-20Hz, je razvrščanje bolj točno z uporabo značilk, pridobljenih z uporabo kompleksnega Pearsonovega korelacijskega koeficienta, čeprav ta, za razliko od Grangerjevega indeksa vzročnosti, ne podaja informacije o usmerjenosti povezav.

Key words documentation

Name and SURNAME: Marko ROZMAN

Title of final project paper: Movement recognition based on electroencephalography

Place: Koper

Year: 2024

Number of pages: 33

Number of figures: 15

Number of tables: 2

Number of references: 15

Mentor: Assist. Prof. Peter Rogelj, PhD

Keywords: electroencephalography, Granger causality index, complex Pearson correlation coefficient, neural network, classification

Abstract:

The purpose of our research is to evaluate the ability to recognize movement based on estimated brain connectivity derived from electroencephalography data. We classified movements from the EEG Motor Movement/Imagery Dataset and data we recorded ourselves using the Cognionics Quick-20 device. From the recordings, we calculated connectivity matrices using the Granger causality index and the complex Pearson correlation coefficient, which we then classified using various algorithms, including neural networks. Our results show that movement can be recognized using features derived from brain connectivity. By using the optimal frequency band, which in our case is 13-20Hz, classification is more accurate with features obtained using the complex Pearson correlation coefficient, even though it does not provide information about the directionality of connections, unlike the Granger causality index.

Zahvala

Iskreno se zahvaljujem svojemu mentorju, doc. dr. Petru Roglju, za neprecenljivo podporo in vodenje pri pisanju diplomske naloge. Njegova strokovna pomoč pri izbiri metod, implementaciji ter pisanju je bila ključnega pomena na vsakem koraku. Hvaležen sem za priložnost dela s fizično napravo in za redne konzultacije ob sredah, ki so pripomogle k jasnosti in uspešnosti mojega dela.

Prav tako se iz srca zahvaljujem prijateljem in družini za njihovo neomajno podporo in spodbudo skozi celoten proces.

Kazalo vsebine

1	Uvod	1
1.1	Elektroencefalografija	2
1.1.1	Mednarodni sistem 10-20 pozicioniranja elektrod	3
1.1.2	Cognionics Quick-20	5
1.2	Možganska povezljivost	5
2	Podatki in metode	7
2.1	Razvojno okolje MATLAB	7
2.1.1	EEGLAB	8
2.1.2	Lab streaming layer	8
2.1.3	Classification learner	9
2.2	Podatkovna zbirka EEG Motor Movement/Imagery Dataset	10
2.3	Metode povezljivosti	10
2.3.1	Grangerjev indeks vzročnosti	11
2.3.2	Kompleksni Pearsonov korelacijski koeficient	11
2.4	Razvrščanje	12
2.4.1	Razvrščanje v okolju Classification learner	12
2.4.2	Razvrščanje z lastno nevronske mreže	12
3	Rezultati	14
3.1	Delitev podatkov	14
3.2	Rezultati na MMID	14
3.2.1	Izbira metode povezljivosti	14
3.2.2	Izbira uporabljenih filtrov	16
3.2.3	Rezultati z okoljem classification learner	17
3.2.4	Rezultati z uporabo lastne nevronske mreže	17
3.3	Rezultati na lastnih podatkih	21
3.4	Sprotno razpoznavanje	21
4	Zaključki	23

Kazalo tabel

1	Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podatkov MMID.	10
2	Točnost vseh testiranih metod razvrščanja v aplikaciji Clasification Learner.	18

Kazalo slik

1	Frekvenčna območja EEG signala.	2
2	Mednarodni sistem 10-20 pozicioniranja elektrod.	3
3	Mednarodni sistem 10-10 pozicioniranja elektrod.	4
4	EEG naprava Cognionics Quick-20. [9]	5
5	Programsko okolje MATLAB.	7
6	Orodjarna EEGLAB.	8
7	Aplikacija Classification learner.	9
8	Arhitektura lastne nevronske mreže.	13
9	Točnost razvrščanja po frekvenčnih območjih in dolžini epoh.	15
10	Točnost razvrščanja glede na tip filtra in frekvenčno območje.	16
11	Matriki zmede nevronske mreže za frekvenčno območje beta.	17
12	Matrika zmede metode Quadratic SVM.	19
13	Matrika zmede lastne nevronske mreže.	20
14	Matrika zmede dodatno naučene nevronske mreže.	21
15	Prikaz sprotnega razpoznavanja	22

Seznam kratic


<i>EEG</i>	elektroencefalografija
<i>MMID</i>	Motor Movement/Imagery Dataset
<i>PLI</i>	phase lag index
<i>wPLI</i>	weighted phase lag index
<i>k - NN</i>	k nearest neighbours
<i>SVM</i>	support vector machine
<i>CPCC</i>	complex Pearson correlation coefficient
<i>GC</i>	Granger causality

1 Uvod

Motivacija za raziskavo je bilo ugotoviti do kakšne mere je mogoča razpoznavanje gibanja v živo na osnovi analize možganske aktivnosti z meritvami elektronecefalografije (EEG). Najprej smo podatke iz prosto dostopne zbirke podatkov s pomočjo knjižnice EEGLAB razdelili na nekaj različno dolgih epoh po dogodkih in jim zožili frekvenčne pasove. Iz vsake pridobljene zbirke podatkov smo pridobili matrike povezljivosti Grangerjevega indeksa vzročnosti in matrike povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta. Na pridobljenih podatkih smo naučili nevronske mreže. Iz pridobljenih rezultatov smo se odločili za nadaljevanje razvoja na zbirki, ki je obetala najboljšo točnost. Da bi omogočili delovanje v realnem času smo sami implementirali nekaj že obstoječih funkcij iz knjižnice. Posneli smo podatke na napravi Cognionics Quick-20 in dodatno naučili nevronske mreže na naših podatkih za boljše razvrščanje.

1.1 Elektroencefalografija


Elektroencefalografija (EEG) je metoda za merjenje možganske električne aktivnosti. Meri električne potenciale na površini temena ki jih deloma generira možganska aktivnost. V zadnjem stoletju so znanstveniki s pomočjo EEG pridobili vpogled v različne nevrološke bolezni. V zadnjem času pa se pojavlja interes v modeliranju EEG signalov in uporabo le teh za nadzor fizičnih naprav (ang. Brain-Computer Interfacing). EEG signali so običajno razdeljeni v frekvenčna območja, ki odražajo različne spektralne vrhove in jih povezujemo z različnimi možganskimi procesi. Ta območja so običajno določena kot delta (1-4 Hz), theta (4-8 Hz), alpha (8-13 Hz), beta (13-20 Hz), in gamma (>20 Hz). Slika 1 [7]




Slika 1: Prvih 8 sekund EEG signala elektrode C3, osebe S001 serije R03. Od zgoraj navzdol po področjih: vsa skupaj, delta, theta, alpha, beta, gamma.

1.1.1 Mednarodni sistem 10-20 pozicioniranja elektrod

Mednarodni sistem 10-20 (slika 2) standardizira mesta elektrod tako, da so te nameščene v mrežo od naziona do iniona ter od desnega do levega sluhovoda v presledkih 10 in 20 odstotkov razdalje. Vsaka elektroda je označena s črko lokacijo: T-Temporal, F-Frontal, P-Parietal, C-Central in O-Occipital, ter s črko z za elektrode na sredini glave, lihimimi števkami za levo polovico glave in sodimi za desno. [1] Poleg mednarodnega sistema 10-20 za pozicioniranje elektrod obstajajo tudi drugi sistemi, kot je na primer mednarodni sistem 10-10 pozicioniranja elektrod. Podatki, snemani v živo, so bili pridobljeni po mednarodnem sistemu 10-20, medtem ko je bila podatkovna zbirka, uporabljena za učenje, snemana po prilagojenem mednarodnem sistemu 10-10 pozicioniranja elektrod.



Slika 2: Prikaz pozicije elektrod po mednarodnem sistemu 10-20. Nameščene v mrežo od naziona do iniona in od levega do desnega sluhovoda v presledkih 10 in 20 odstotkov. [12]



Slika 3: Prikaz pozicije elektrod po mednarodnem sistemu 10-10 pozicioniranja elektrod.

[13]

1.1.2 Cognionics Quick-20

Cognionics Quick-20 (slika 4) je brezžična EEG naprava s suhimi elektrodami za raziskovalne namene. Ima 21 elektrod postavljenih po mednarodnem sistemu 10-20 za pozicioniranje elektrod. Naprava je suhega tipa kar pomeni, da pri uporabi elektrode ne potrebujejo gela. Suhi tipi naprav so v primerjavi z mokrimi enostavni in udobni za uporabo in omogočajo hitro nastavitve. Naprava je brezžična, z računalnikom jo povežemo preko USB vmesnika. [10]



Slika 4: EEG naprava Cognionics Quick-20. [9]

1.2 Možganska povezljivost

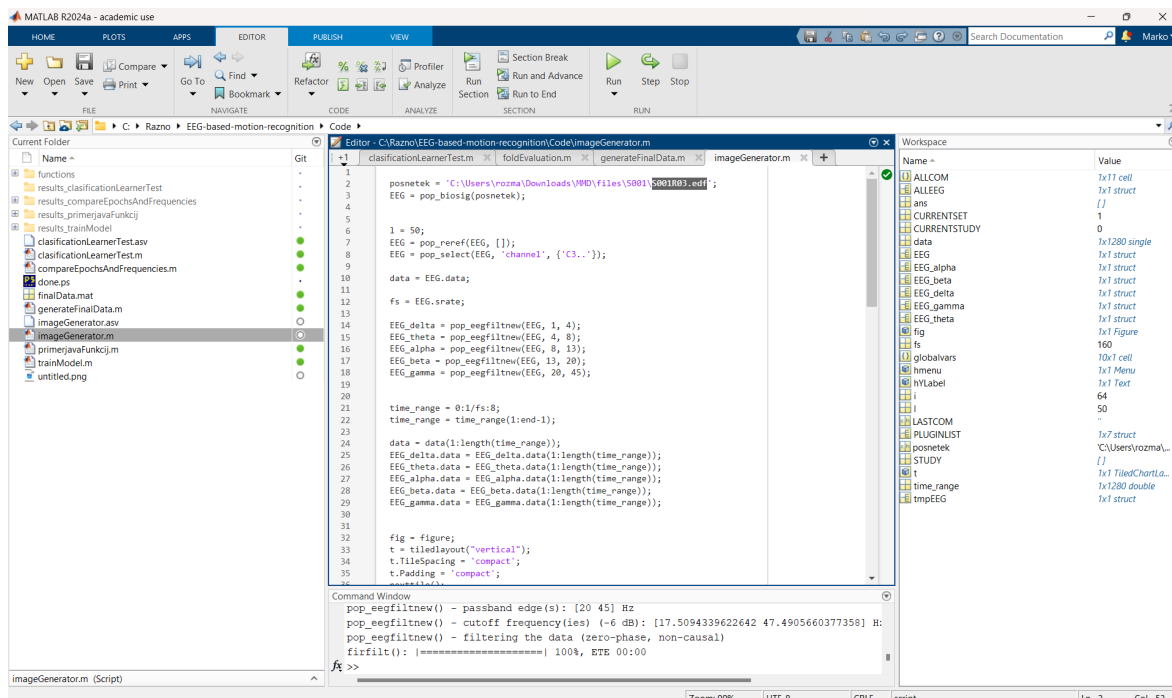
Možganska povezljivost se nanaša na vzorce nastale zaradi anatomskih povezav možganov, statistične odvisnosti ali interakcij med posameznimi deli možganov. Enote med katerimi se meri povezljivost so lahko različne: posamezni nevroni, nevronske populacije, v našem primeru pa regije možganske skorje. Možganska aktivnost je omejena s povezljivostjo, le ta pa je zato ključnega pomena za razumevanje delovanja možganov. V grobem poznamo dve vrsti povezljivosti: strukturno in funkcijsko. Strukturna povezanost se nanaša na to kako so deli možganov med seboj fizično povezani. Funkcijska povezljivost pa se nanaša na to kako različni deli možganov med seboj komunicirajo oziroma sodelujejo. [4] Funkcijsko povezljivost lahko nadaljnjo delimo na usmerjeno in neusmerjeno. V našem primeru je metoda Grangerjevega indeksa vzročnosti usmerjena

saj je vpliv elektrode A na elektrodo B drugačen kot vpliv elektrode B na elektrodo A . Metoda kompleksnega Pearsonovega korelacijskega koeficienta pa je neusmerjena saj nam njegova vrednost pove le o povezanosti para elektrod. Pri njej se ne ugotavlja smer vpliva. V izrazu Grangerjev indeks vzročnosti je vzorčnost zavajajoč termin saj nam Grangerjev indeks vzročnosti nakazuje da ena stvar vpliva na drugo vendar sta lahko v določenih primerih obe meritvi odvisni od nečesa drugega.

2 Podatki in metode

2.1 Razvojno okolje MATLAB


Ves razvoj je potekal v programskem okolju MATLAB. Ta poleg samega programskega jezika vsebuje velik nabor že implementiranih funkcij, napredne aplikacije za strojno učenje in knjižnice ki omogočajo povezave z laboratorijskimi napravami. V njem sta ustvarjeni funkciji za računanje matrik Grangerjevega indeksa vzročnosti in matrik Kompleksnega Pearsonov korelacijskega koeficienta, prav tako so v njem ustvarjene nevronske mreže in uporabljeno je za ostala razvrščanja in funkcijo za zajemanje podatkov iz naprave Cognionics Quick-20 ter funkcijo ki v realnem času razpoznava gibanje. [15]



Slika 5: Programsko okolje MATLAB. Od leve proti desni: podokno z datotekami, podokno s kodo, podokno s spremenljivkami. Zgoraj zavihki za orodjarno, aplikacije in prikaz podatkov.

2.1.1 EEGLAB

EEGLAB je interaktivna matlab orodjarna, za procesiranje in obdelavo elektrofizioloških podatkov. Omogoča rereferenciranje EEG signalov, izbiro določenih elektrod, deljenje podatkov na epohe glede na dogodke in filtriranje frekvenc. Omogoča interakcijo preko uporabniškega vmesnika. Vse akcije v vmesniku se prevedejo v ukaze. Grafični vmesnik je uporaben za enostavne analize. Za avtomatizacijo pa njegove funkcije uporabimo v svoji kodi z ustreznimi ukazi. Pri izdelavi naloge smo največ uporabljali funkcije branja .edf datotek, filtriranja frekvenc signalov in deljenja posnetkov na manjše dele.[11]




Slika 6: Orodjarna EEGLAB. Zgoraj zavihki za delo z datotekami, urejanje, orodja, prikaz podatkov, delo z zbirkami podatkov in pomoč. Naložen podatkovni niz dolžine 124 sekund z 30 dogodki.

2.1.2 Lab streaming layer

Lab streaming layer je odprtokodna vmesna programska oprema ki omogoča pošiljanje, prejemanje, sinhronizacijo in snemanje tokov podatkov znotraj lokalnega omrežja. Med drugim je na voljo v obliki MATLAB knjižnice, ki omogoča preprosto integracijo EEG naprav s programsko opremo MATLAB. Knjižnico je potrebno prenesti in nato zgraditi na svojem računalniku. [14]

2.1.3 Classification learner

Classification learner je aplikacija v okolju MATLAB za enostavno razvrščanje podatkov. Podpira različne metode razvrščanja, prečno preverjanje in uporabo različnih podatkov za gradnjo in testiranje modela. Aplikacija podpira razvrščanje podatkov iz dvo dimenzionalnih matrik kjer vrstice ali stolpci predstavljajo spremenljivke. Oznake podatkov lahko podamo kot določeno vrstico ali stolpec matrike ali v ločeni spremenljivki. Zaradi omejitev aplikacije smo pred razvrščanjem matrike povezljivosti pretvorili v vektorje in te združili v matriko podatkov. Z aplikacijo smo lahko enostavno primerjali delovanje različnih razvrščanj v primerjavi z lastno nevronske mreže, ki smo jo izvedli zunaj aplikacije Classification learner.



Slika 7: Aplikacija Classification learner. Na levi strani podokno z različnimi metodami razvrščanja, na sredini prikaz podrobnosti izbrane metode. Zgoraj zavihki za učenje, testiranje in razlago.

2.2 Podatkovna zbirka EEG Motor Movement/Imagery Dataset

EEG Motor Movement/Imagery Dataset(MMID) je prosto dostopna zbirka več kot 1500 eno in dve minutnih posnetkov 109 prostovoljcev. Zbirka za vsakega prostovoljca vsebuje dva izhodiščna posnetka in po tri posnetke opravljanja štirih različnih nalog: stiskanje in sproščanje leve ali desne pesti(naloga 1), namišljeno stiskanje in sproščanje leve ali desne pesti(naloga 2), stiskanje in sproščanje obeh pesti ali obeh stopal(naloga 3), namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal(naloga 4). Za nas relevantni so posnetki serij 3, 7 in 11 v katerih prostovoljci opravljajo prvo nalogo. Posnetki so shranjeni v formatu EDF+ ki vsebuje posnetke EEG in oznake dogodkov. Snemanje je bilo opravljeno z sistemom BCI2000 z 64 elektrodami postavljenimi po mednarodnem sistemu 10-10(slika 3) brez elektrod Nz, F9, F10, FT9, FT10, A1, A2, TP9, TP10, P9, in P10.[2, 5]

Številka serije	Naloga	Opis naloge
1	izhodišče	odprte oči
2	izhodišče	zaprte oči
3	naloga 1	stiskanje in sproščanje leve ali desne pesti
4	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
5	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
6	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
7	naloga 1	stiskanje in sproščanje leve ali desne pesti
8	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
9	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
10	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal
11	naloga 1	stiskanje in sproščanje leve ali desne pesti
12	naloga 2	namišljeno stiskanje in sproščanje leve ali desne pesti
13	naloga 3	stiskanje in sproščanje obeh pesti ali obeh stopal
14	naloga 4	namišljeno stiskanje in sproščanje obeh pesti ali obeh stopal

Tabela 1: Naloge in opisi nalog, ki jih prostovoljci opravljajo v posnetkih zbirke podatkov MMID.

2.3 Metode povezljivosti

Metode povezljivosti se uporabljajo za analizo delovanja možganov, saj nam v nasprotju z direktnim razvrščanjem EEG signalov omogočajo identifikacijo specifičnih vzorcev.

S tem pridobimo globlji vpogled v delovanje možganov.

2.3.1 Grangerjev indeks vzročnosti

Grangerjev indeks vzročnosti je statistična metoda za preverjanje, ali ena časovna vrsta nosi informacije o drugi. Metoda je bila razvita v šestdesetih letih devetnajstega stoletja za uporabo ekonomiji.[6]

Za dve časovni vrsti X_1 in X_2 ter red p (ang. order) kot število prejšnjih vrednosti, ki jih upoštevamo pri računanju, lahko izračunamo E_1 in E_2 ki so napake pri predvidevanju naslednje vrednosti v vrsti X_1 . A_1 , A_2 in A_3 so koeficienti avto-regresivnega modela. [3]

$$X_1(t) = \sum_{j=1}^p A_{1,j} X_1(t-j) + E_1(t)$$

$$X_1(t) = \sum_{j=1}^p A_{2,j} X_1(t-j) + \sum_{j=1}^p A_{3,j} X_2(t-j) + E_2(t)$$

V kolikor je varianca vrednosti E_2 manjša kot varianca vrednosti E_1 lahko predvidamo, da časovna vrsta X_2 nosi informacije o časovni vrsti X_1 . [3]

Sam indeks vzročnosti pa izračunamo po formuli:

$$GC = \log \left(\frac{\text{varianca}(E_1)}{\text{varianca}(E_2)} \right)$$

2.3.2 Kompleksni Pearsonov korelacijski koeficient

Pearsonov korelacijski koeficient je najpogosteje uporabljen linearni korelacijski koeficient. Zanj smo se odločili saj v članku »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis« avtorji pokažejo da vsebuje informacije Phase Locking Value(PLV) in Weighted Phase Lag Index(wPLI) ki sta dve najbolj pogosto uporabljeni metodi poveztivosti. V praksi nam pove, v kakšni meri sta fazi dveh signalov linearno povezani.[8]

Ker želimo opazovati faze EEG signala, ga potrebujemo pretvoriti v analitični signal ki vsebuje informacijo o fazi. Da je informacija o fazi bolj verodostojna in informativna, mora biti signal omejen na ožje frekvenčno področje, kar dosežemo s predhodnim filtriranjem. Analitični signal X_a kjer $HT(X(t))$ označuje Hilbertovo transformacijo signala X . [8]

$$X_a(t) = X(t) + i \cdot HT(X(t))$$

Za računanje Kompleksnega Pearsonovega korelacijskega koeficienta v našem primeru lahko uporabimo naslednjo enačbo kjer sta X_1 in X_2 analitična signal dolžine N .

$\overline{X_2(n)}$ pa konjugirana vrednost $X_2(n)$ [8]

$$r(X_1, X_2) = \frac{\sum_{n=1}^N (X_1(n) \cdot \overline{X_2(n)})}{\sqrt{\sum_{n=1}^N |X_1(n)|^2} \cdot \sqrt{\sum_{n=1}^N |X_2(n)|^2}}$$

2.4 Razvrščanje


Želeli smo preizkusiti kako uspešno bi razvrščanje delovala na podatkih zbirke in kako uspešno bi delovala na naših podatkih, zato smo razvrščanje izvajali dvakrat. Enkrat na podatkih zbirke in enkrat na naših podatkih. Ker nevronska mreža za učenje potrebuje več podatkov kot jih lahko zagotovimo iz naših posnetkov smo jo za namene razvrščanja naših posnetkov naučili na podatkih MMID in nato dodatno naučili na naših podatkih.

2.4.1 Razvrščanje v okolju Classification learner

Na matrikah povezljivosti pridobljenih iz podatkov zbirke in naših posnetkov smo izvedli več različnih vrst razvrščanja, že implementiranega v aplikaciji Clasification learner in sicer: odločitvena drevesa, metodo k najbližjih sosedov (k-NN), logistično regresijo, podporne vektorske stroje (SVM), ansabelske metode in nevronske mreže.

2.4.2 Razvrščanje z lastno nevronske mreže

Za lastno implementacijo nevronske mreže smo se odločili saj nam ta nudi možnost enostavnejše nadaljnje analize razlogov za klasifikacijo. Nevronska mreža je sestavljena iz vhodne plasti dimenzij 19x19x1 za dvodimenzionalne podatke, kakršne so matrike povezljivosti, polno povezane plasti s 100 nevroni, Leaky ReLU(usmerjena linearna enota) plasti, dropout(izpust) plasti z 50% verjetnostjo izpustitve nevronov, polno povezane plasti z 10 nevroni, GELU plasti, dropout(izpust) plasti z 50% verjetnostjo izpustitve nevronov, polno povezane plasti s tremi nevroni in softmax plasti. Mreža je realizirana z pomočjo MATLAB orodjarne Deep Learning Toolbox.



Slika 8: Arhitektura lastne nevronske mreže v MATLAB aplikaciji Deep Network Designer. Od zgoraj navzdol: plast za dvodimenzionalne podatke, polno povezana plast, Leaky ReLU(usmerjena linearna enota), dropout(izpust), polno povezana plast, GELU, dropout(izpust), polno povezana plast in Softmax.

3 Rezultati

3.1 Delitev podatkov


Za končno raziskavo smo izbrali posnetke serij 3, 7 in 11 iz MMID. Vsaka serija vsebuje 109 posnetkov, vsak posnetek 30 primerov stanj, vse skupaj smo jih pridobili 9854. Primere stanj smo skrčili na enakomerno razporeditev, z 2456 primeri vsakega stanja. Sami smo posneli nekaj minut posnetkov. Vse skupaj 250 primerov stanj, ki smo jih skrčili na enakomerno razporeditev, 62 primerov vsakega stanja. Za učenje nevronske mreže smo uporabljali množice za učenje s 75% podatkov in množice za testiranje s 25% podatkov. Podatki so bili naključno razporejeni med učno in testno množico. Ker smo podatke delili naključno, se lahko različni posnetki stanj istega prostovoljca pojavijo v učni in testni množici. Pri dodatnem učenju mreže smo uporabili posnetke ene osebe za učenje in testiranje. To skupaj pomeni da sistem ne deluje medosebno.

3.2 Rezultati na MMID


Za izbiro metode povezljivosti, načina filtriranja, dolžine epohe in frekvenčnega pasu smo uporabili podatkovno zbirko MMID. Pri interpretaciji točnosti razvrščanja stanj je treba upoštevati, da razvrščamo tri različna stanja. Zato so že rezultati okoli 50% bistveno nad nivojem naključnosti, ki je v primeru treh različnih stanj 33%.

3.2.1 Izbira metode povezljivosti

Ker je kompleksni Pearsonov korelacijski koeficient (CPCC) izračunan iz analitičnih signalov ga lahko definiramo samo za ozke frekvenčne pasove. Pri računanju Grangerjevega indeksa vzročnosti (GC) te omejitve ni, tako da smo ga lahko računali na celotnem frekvenčnem območju do 45Hz. Prav tako se je pojavilo vprašanje koliko dolgo epoho EEG signala bomo potrebovali za uspešno razvrščanje. Kot možnosti smo vzeli prvo sekundo, prvi dve sekundi, drugi dve sekundi in prve štiri sekunde po dogodku. Točnost razvrščanja smo ocenili z zgoraj navedeno nevronske mrežo. Za najboljšo metodo se je izkazal kompleksni Pearsonov korelacijski koeficient na območju 13-20Hz z najdaljšimi epohami, 4s. Celotno območje primerjav razvidno iz slike 9.



Slika 9: Točnost razvrščanja po frekvenčnih območjih in dolžini epoh za CPCC in GC. Od zgoraj navzdol CPCC po pasovih delta, theta, alpha, beta in gamma. Spodnja vrstica Grangerjev indeksa vzorčnosti. Epohe od leve proti desni: prva sekunda, prvi dve sekundi, drugi dve sekundi, prve štiri sekunde.



Slika 10: Primerjava točnosti razvrščanja glede na tip filtra. Uporabljena metoda CPCC za epoko prvih štirih sekund za frekvenčne pasove delta, theta, alpha, beta in gamma. Razvrščanje z zgoraj navedeno nevronske mreže. Modra predstavlja Butterworthov filter, oranžna predstavlja filter z ničelno fazo.

3.2.2 Izbira uporabljenih filtrov

Knjižnica EEGLAB vsebuje samo filtre z ničelno fazo, ki filtrirajo naprej in nato nazaj po času, kar v našem primeru ni primerno saj podatke prejemamo sekvenčno. Filtrov z ničelno fazo se ne da uporabiti v realnem času. Podatke smo želeli filtrirati s pomočjo Butterworthovega filtra ki vsebuje stanja. Stanja nam omogočajo filtriranje sekvenčnih podatkov saj preprečijo napako na začetku filtra kjer le ta potrebuje predpostaviti začetno stajanje vseh signalov 0. Ker filtra nista enakovredna saj prvi ne spreminja faz drugi pa jih zamakne, uporabljena metoda CPCC pa deluje na zamikih faz, smo izvedli dodatno testiranje, da smo preverili če pristop deluje enako učinkovito. Razvrščanje matrik pridobljenih z Butterworthovim filtrom (slika 11b) v primerjavi z filtrom z ničelno fazo (slika 11a) je bilo primerljivo točno za frekvenčni pas beta (slika 10) iz česar lahko sklepamo, da je filtriranje z Butterworthovim filtrom primerno.

		EEGLAB						Butterworth			
Output Class	rest	425 21.2%	117 5.8%	128 6.4%	63.4% 36.6%	rest		442 22.1%	122 6.1%	161 8.0%	61.0% 39.0%
	left	145 7.2%	374 18.7%	285 14.2%	46.5% 53.5%	left		111 5.5%	355 17.7%	238 11.9%	50.4% 49.6%
	right	98 4.9%	117 8.8%	255 12.7%	48.1% 51.9%	right		115 5.7%	191 9.5%	269 13.4%	46.8% 53.2%
		63.6% 36.4%	56.0% 44.0%	38.2% 61.8%	52.6% 47.4%			66.2% 33.8%	53.1% 46.9%	40.3% 59.7%	53.2% 46.8%
		Target Class						Target Class			
		rest	left	right				rest	left	right	

Slika 11: Matriki zmede nevronske mreže naučene na podatkih filtriranih s filtrom z ničelno fazo (levo) in Butterworthovim filtrom (desno). Uporabljena metoda CPCC za epoko prvih štirih sekund za frekvenčni pas beta. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: stanje mirovanja, skrčena leva pest, skrčena desna pest.

3.2.3 Rezultati z okoljem classification learner


Z uporabo aplikacije classification learner smo testirali več načinov razvrščanja. Iz rezultatov predstavljenih v tabeli 2 lahko razberemo, da so se za najbolj uspešne izkazale metode podpornih vektorjev (SVM), vendar so te metode računsko zahtevne kar otežuje izvedbo v realnem času. Dober kandidat bi lahko bila odločitvena drevesa saj so enostavna za učenje in interpretacijo, vendar so le ta dosegla 41% točnost. Nevronske mreže ki jih podpira aplikacija so enostavne, vendar pa je njihova interpretacija težja. Dosegle so 49% točnost.

3.2.4 Rezultati z uporabo lastne nevronske mreže


Nato smo poskusili z zgoraj navedeno nevronske mrežo, ki razvršča matrike povezlivosti. Mreža je dosegla enako točnost kot metode iz aplikacije Classification learner in sicer 52%. Če primerjamo matriko zmede nevronske mreže z matriko zmede metode SVM (sliki 13 in 12), opazimo, da obe metodi bolj natančno razlikujeta stanje mirovanja od obeh stanj gibanja, medtem ko je razlikovanje med stanji gibanja med seboj manj natančno.

vrsta razvrščanja	metoda	točnost [%]
SVM	Quadratic SVM	53
SVM	Linear SVM	53
SVM	Medium Gaussian SVM	53
Ensemble	Subspace Discriminant	53
SVM	Cubic SVM	52
Kernel	SVM Kernel	52
Kernel	Logistic Regression Kernel	52
SVM	Coarse Gaussian SVM	50
Efficient Logistic Regression	Efficient Logistic Regression	49
Neural Network	Wide Neural Network	49
Neural Network	Medium Neural Network	47
Efficient Linear SVM	Efficient Linear SVM	46
Neural Network	Trilayered Neural Network	45
Neural Network	Bilayered Neural Network	45
Naive Bayes	Kernel Naive Bayes	45
Neural Network	Narrow Neural Network	45
Ensemble	Bagged Trees	44
KNN	Coarse KNN	44
Ensemble	Boosted Trees	43
Ensemble	RUSBoosted Trees	42
Tree	Medium Tree	41
Tree	Fine Tree	41
KNN	Cosine KNN	41
Tree	Coarse Tree	41
KNN	Medium KNN	40
KNN	Weighted KNN	40
Ensemble	Subspace KNN	40
KNN	Cubic KNN	40
KNN	Fine KNN	38
SVM	Fine Gaussian SVM	37

Tabela 2: Točnost vseh testiranih metod razvrščanja v aplikaciji Clasification Learner.



Slika 12: Matrika zmede metode Quadratic SVM. V poljih vidno število stanj. Od zgoraj navzdol: stanje mirovanja, skrčena leva pest, skrčena desna pest.



Slika 13: Matrika zmede lastne nevronske mreže. V zelenih poljih vidna točnost za posamezna stanja. Od zgoraj navzdol: stanje mirovanja, skrčena leva pest, skrčena desna pest.

		Confusion Matrix			
Output Class	rest	25 13.4%	15 8.1%	16 8.6%	44.6% 55.4%
	left	15 8.1%	34 18.3%	24 12.9%	46.6% 53.4%
	right	22 11.8%	13 7.0%	22 11.8%	38.6% 61.4%
		40.3% 59.7%	54.8% 45.2%	35.5% 64.5%	43.5% 56.5%
		rest	left	right	
		Target Class			

Slika 14: Matrika zmede nevronske mreže dodatno naučene na naših podatkih.

3.3 Rezultati na lastnih podatkih

Da bi se približali delovanju v realnem času, smo nevronske mreže dodatno naučili na naših podatkih. Zaradi različnih pogojev snemanja in natančnosti naprav na katerih so podatki snemani je točnost razvrščanja pričakovano padla. Dosegli smo 43% točnost. Ker nimamo velikega števila posnetkov smo uporabili petkratno prečno preverjanje.

3.4 Sprotno razpoznavanje

Po razvoju pristopov na zbirkah podatkov smo implementirali sprotno razpoznavanje. Uporabili smo programsko opremo Lab Streaming Layer, da smo prenašali podatke iz naprave Quick-20 v okolje MATLAB. Tam smo podatke združevali in iz njih vsako sekundo izračunali matriko povezljivosti z metodo CPCC za frekvenčno območje beta, filtrirano z Butterwithovim filtrom. Matriko povezljivosti smo razvrstili in rezultat razvrščanja izpisali na zaslon. Na natančnost sprotnega razvrščanja matrik povezlji-



Slika 15: Prikaz sprotnega razpoznavanja. Dodan izpis razvrščanja iz okolja MATLAB.

vosti ene osebe vpliva veliko dejavnikov. Nanj vpliva razpoloženje osebe, namestitvev naprave, sam dogodek ki ga razvrščamo pa tudi motje v okolju, ki vplivajo na osebo in na napravo. Točnosti razvrščanj nismo natančno izmerili, ocenjujemo pa, da je nižja od tiste, ki smo jo dosegli na prej posnetih podatkih. Kljub temu je iz rezultatov razvidno, da je klasifikacija gibanja v realnem času mogoča.

4 Zaključki

V nalogi smo uspešno razpoznali gibanje iz EEG signalov. Uspešno smo razpoznali gibanje iz podatkovne zbirke MMID posnete po mednarodnem sistemu 10-10 in iz podatkov posnetih na napravi Cognionics Quick-20. Posnete signale smo obdelali z različnimi pristopi. Signale smo rereferencirali, filtrirali z filtrom z ničelno fazo in butterworthovim filtrom na običajna območja zanimanja pri analizi EEG signalov. Nato smo signale razdelili na različno dolge epohe in izbrali najustreznejše. Obdelane signale smo pretvorili v matrike povezljivosti s pomočjo Granjgerjevega indeksa vzorčnosti in kompleksnega Pearsonovega korelacijskega koeficienta. Pridobljene matrike smo razvrstili z aplikacijo Clasification Learner in z nevronske mreže ki smo jo implementirali sami. Dosegli smo zadovoljive točnosti na podatkih MMID in podatkih posnetih z napravo Cognionics Quick-20. Metode ki smo jih uporabljali omogočajo nadaljnjo analizo, ki lahko prispeva k boljšemu razumevanju možganskih aktivnosti kot direktno razvrščanje signalov. Z uporabo kompleksnega Pearsonovega korelacijskega koeficienta smo pokazali, da je razpoznavanje gibanja mogoče iz krajših epoh območja beta. Ugotovili smo, da kompleksni Pearsonov korelacijski koeficient zagotavlja boljšo metodo za izračun povezljivosti kot tradicionalno uporabljeni Grangerjev indeks vzročnosti. Za delo v realnem času smo sami implementirali in ocenili primernost filtrov ki jih knjižnica EEGLAB ne podpira. Pokazali smo, da je sprotno razvrščanje mogoče z metodo povezljivosti kompleksnega Pearsonovega korelacijskega koeficienta.

Glavne omejitve ki nam onemogočajo točnejše razvrščanje z uporabljenimi metodami so omejena velikost posnetkov in omejena natančnost naprav EEG. Prav tako naloga vsebuje omejitev pri učenju klasifikatorjev, saj sistema nismo preizkusili pri razvrščanju EEG signalov oseb na čigar signalih klasifikator ni bil učen. Točnost sprotnega razvrščanja signalov ene osebe pa je dodatno omejena z njenim razpoloženjem.

Razpoznavanje gibanja iz signalov EEG ima potencialne aplikacije v medicini, zlasti pri razvoju sistemov za nadzor protez in rehabilitacijskih naprav. Metode povezljivosti, uporabljene v nalogi pa nam lahko poglobijo razumevanje možganske aktivnosti med različnimi fizičnimi nalogami.

Literatura

- [1] G. H. Klem in sod. »The Ten-Twenty Electrode System of the International Federation. The International Federation of Clinical Neurophysiology«. V: *Electroencephalography and Clinical Neurophysiology. Supplement* 52 (1999), str. 3–6. ISSN: 0424-8155. pmid: 10590970.
- [2] Gerwin Schalk in sod. »BCI2000: A General-Purpose Brain-Computer Interface (BCI) System«. V: *IEEE transactions on bio-medical engineering* 51.6 (jun. 2004), str. 1034–1043. ISSN: 0018-9294. DOI: 10.1109/TBME.2004.827072. pmid: 15188875.
- [3] Anil Seth. »Granger Causality«. V: *Scholarpedia* 2.7 (6. jul. 2007), str. 1667. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.1667. URL: http://www.scholarpedia.org/article/Granger_causality (pridobljeno 16. 6. 2024).
- [4] Olaf Sporns. »Brain Connectivity«. V: *Scholarpedia* 2.10 (28. okt. 2007), str. 4695. ISSN: 1941-6016. DOI: 10.4249/scholarpedia.4695. URL: http://www.scholarpedia.org/article/Brain_connectivity (pridobljeno 16. 6. 2024).
- [5] Gerwin Schalk in sod. *EEG Motor Movement/Imagery Dataset*. physionet.org, 2009. DOI: 10.13026/C28G6P. URL: <https://physionet.org/content/eegmimdb/> (pridobljeno 13. 6. 2024).
- [6] Mike X Cohen. *Analyzing Neural Time Series Data: Theory and Practice*. The MIT Press, 17. jan. 2014. ISBN: 978-0-262-31955-3. DOI: 10.7551/mitpress/9609.001.0001.
- [7] Michael Nunez, Paul Nunez in Ramesh Srinivasan. »Electroencephalography (EEG): Neurophysics, Experimental Methods, and Signal Processing«. V: 1. jan. 2016, str. 175–197. ISBN: 978-1-4822-2097-1. DOI: 10.13140/RG.2.2.12706.63687.
- [8] Zoran Šverko in sod. »Complex Pearson Correlation Coefficient for EEG Connectivity Analysis«. V: *Sensors (Basel, Switzerland)* 22.4 (14. feb. 2022), str. 1477. ISSN: 1424-8220. DOI: 10.3390/s22041477. pmid: 35214379. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8879969/> (pridobljeno 17. 6. 2024).

- [9] *Cognionics QUICK-20 User Manual (Page 28 of 41) | ManualsLib*. URL: <https://www.manualslib.com/manual/2823961/Cognionics-Quick-20.html?page=28#manual> (pridobljeno 9. 7. 2024).
- [10] *Dry EEG Headset | Quick-20r*. CGX. URL: <https://www.cgxsystems.com/quick-20r-v2> (pridobljeno 20. 6. 2024).
- [11] *EEGLAB*. URL: <https://sccn.ucsd.edu/eeglab/index.php> (pridobljeno 13. 6. 2024).
- [12] *Electrode Arrangement According to the International 10/20 System*. URL: <https://www.ternimed.de/EEG-Electrode-arrangement-according-to-the-international-10/20-system> (pridobljeno 20. 6. 2024).
- [13] https://www.physionet.org/content/eegmmidb/1.0.0/64_channel_sharbrough.pdf. URL: https://www.physionet.org/content/eegmmidb/1.0.0/64_channel_sharbrough.pdf (pridobljeno 26. 6. 2024).
- [14] *Lsl-Website*. URL: <https://labstreaminglayer.org/#/> (pridobljeno 13. 6. 2024).
- [15] *MATLAB*. URL: <https://www.mathworks.com/products/matlab.html> (pridobljeno 2. 7. 2024).